

Pulso - Predice, nutre, entrena y protege tu corazón

Plataforma PWA con IA para la Prevención Cardiovascular Global:

Predicción de Riesgo, Alimentación, Ejercicio y Seguimiento

Personalizado

Natalia Moncaleano Montero

Agustín Peralta Guarín

Diego Fernando Fandiño Olarte

Universidad de San Buenaventura

Facultad de Ingeniería (Bogotá)

Ingeniería de Sistemas

Bogotá D.C., Colombia

2026

DEDICATORIA

Dedicamos este trabajo a nuestras familias, por su amor incondicional, comprensión y apoyo constante durante todo el proceso de formación profesional. A nuestros padres, quienes con su esfuerzo, valores y ejemplo nos impulsaron a superar cada reto y alcanzar nuestras metas.

También dedicamos este logro a nuestros docentes, por compartir su conocimiento y guiarnos con paciencia y compromiso, y a todas las personas que creyeron en nosotros y nos motivaron a culminar con éxito este proyecto. Este trabajo es reflejo del esfuerzo conjunto, la perseverancia y la pasión que compartimos como grupo.

ÍNDICE

Dedicatoria	1
Resumen	4
Abstract	5
1. Introducción	6
2. Planteamiento del Problema	7
3. Justificación	9
3.1. Relevancia Social	9
3.2. Relevancia Teórica	9
3.3. Relevancia Práctica	9
4. Objetivos	11
4.1. Objetivo General	11
4.2. Objetivos Específicos	11
5. Alcance y Limitaciones	12
5.1. Alcance	12
5.2. Limitaciones	12
6. Diseño del Motor de Predicción	15
6.1. Principios de Diseño	15
6.2. Arquitectura	15
6.3. Preparación de las Series	15
6.4. Modelos de Pronóstico y Selección por Backtesting	16
6.5. Índice de Riesgo Modificable	17
6.6. Detección de Cambios Sostenidos	19
6.7. Módulo de Aprendizaje Supervisado	19
6.8. Integración con la Aplicación y con el Modelo de Lenguaje	20
6.9. Verificación del Software	20
7. Datos y Protocolo de Entrenamiento y Evaluación	21
7.1. Cohorte Sintética con Parámetros Conocidos	21
7.2. Muestra Analítica de NHANES 2021-2023	21

Pulso - Predice, nutre, entrena y protege tu corazón	3
7.3. UCI Heart Disease	21
7.4. Protocolo de Evaluación	23
8. Resultados	24
8.1. Pronóstico Frente a Benchmarks	24
8.2. Detección de Cambios Sostenidos	24
8.3. Estimador de Riesgo sobre NHANES	26
8.4. Validación de la Implementación sobre UCI	32
8.5. Consecuencias para el Diseño	32
9. Conclusiones	34
Referencias	35
Anexo A. Reproducibilidad	40

RESUMEN

Las enfermedades cardiovasculares (ECV) constituyen la principal causa de muerte en el mundo. De acuerdo con la Organización Mundial de la Salud (2026a), cada año fallecen cerca de 20,5 millones de personas por esta causa, lo que equivale a una de cada tres muertes registradas globalmente. La carga es desigual: los países de ingresos medios y bajos concentran la mayor mortalidad evitable, en buena parte porque sus poblaciones no acceden a herramientas de tamizaje y orientación preventiva.

En ese contexto, este proyecto desarrolla **Pulso**, una Aplicación Web Progresiva (PWA) de prevención cardiovascular que articula estimación de riesgo, recomendaciones de alimentación, vida saludable y ejercicio, y seguimiento con dashboard. Su núcleo técnico es un **motor de predicción propio**, implementado desde cero en TypeScript, sin librerías de aprendizaje automático ni servicios de inteligencia artificial generativa, que integra tres componentes: el pronóstico de las series temporales de cada usuario con ocho modelos, cuatro de ellos benchmarks, seleccionados por backtesting según el error escalado MASE; un índice de riesgo modificable de tipo log-lineal con coeficientes de meta-análisis y atribución exacta por factor; y la detección de cambios sostenidos mediante cartas CUSUM y EWMA. Un módulo de aprendizaje supervisado (regresión logística por IRLS, gradient boosting y k vecinos más cercanos) permite entrenar y validar el estimador con datos reales.

Sobre una cohorte sintética de 28 series con parámetros conocidos, el modelo que el motor selecciona supera al pronóstico ingenuo en 23 de ellas, y CUSUM detecta los cuatro cambios de régimen con un retraso medio de 4,5 días. Sobre 5.043 adultos de la Encuesta Nacional de Examen de Salud y Nutrición de los Estados Unidos, ciclo 2021-2023 (Centers for Disease Control and Prevention [CDC], 2024), con 11,8 % de antecedente cardiovascular y validación cruzada estratificada 5×10 , el índice del motor, sin entrenamiento, alcanza un área bajo la curva ROC de 0,611 frente a 0,564 del puntaje heurístico previo, y una regresión logística entrenada con las mismas variables no lo mejora (0,608). Al incorporar edad y sexo, el índice llega a 0,799 y la regresión logística a 0,805, con pendiente de calibración de 0,99; la diferencia entre ambos no es estadísticamente significativa. Los coeficientes estimados coinciden con una implementación independiente en numpy con diferencias del orden de 10^{-14} . El modelo de lenguaje se limita a redactar sobre los números que el motor calcula.

Palabras clave: enfermedades cardiovasculares, aprendizaje automático, series temporales, regresión logística, validación cruzada, estimación de riesgo, NHANES, PWA, salud digital.

ABSTRACT

Cardiovascular diseases (CVDs) are the leading cause of death worldwide. According to the World Health Organization (2026a), approximately 20.5 million people die from CVDs every year, accounting for nearly one in every three recorded deaths. The burden is unequally distributed: low- and middle-income countries concentrate most of the preventable mortality, largely because their populations lack access to screening tools and preventive guidance.

This work presents **Pulso**, a cardiovascular prevention Progressive Web Application (PWA) that combines risk estimation, dietary, lifestyle and exercise recommendations, and dashboard-based tracking. Its technical core is an **in-house prediction engine**, implemented from scratch in TypeScript with no machine learning libraries and no generative AI services, made of three components: per-user time series forecasting with eight models, four of them benchmarks, selected by backtesting on the scaled error MASE; a log-linear index of modifiable risk with meta-analysis coefficients and exact per-factor attribution; and detection of sustained changes with CUSUM and EWMA control charts. A supervised learning module (logistic regression fitted by IRLS, gradient boosting and k-nearest neighbours) makes it possible to train and validate the estimator on real data.

On a synthetic cohort of 28 series with known parameters, the model selected by the engine beats the naïve forecast in 23 of them, and CUSUM detects all four regime changes with a mean delay of 4.5 days. On 5,043 adults from the United States National Health and Nutrition Examination Survey, 2021-2023 cycle (Centers for Disease Control and Prevention [CDC], 2024), with an 11.8% prevalence of cardiovascular history and 5×10 stratified cross-validation, the untrained engine index reaches an area under the ROC curve of 0.611 against 0.564 for the previous heuristic score, and a logistic regression trained on the same variables does not improve on it (0.608). When age and sex are added, the index reaches 0.799 and the logistic regression 0.805, with a calibration slope of 0.99; the difference between them is not statistically significant. The estimated coefficients match an independent numpy implementation with differences of the order of 10^{-14} . The language model only writes text around the figures computed by the engine.

Keywords: cardiovascular diseases, machine learning, time series, logistic regression, cross-validation, risk estimation, NHANES, PWA, digital health.

1. INTRODUCCIÓN

Las enfermedades cardiovasculares (ECV) son hoy uno de los problemas de salud pública más serios a nivel global. La Organización Mundial de la Salud (2026a) estima en 20,5 millones las muertes anuales por esta causa, cifra que equivale al 33 % de toda la mortalidad mundial y que viene en aumento sostenido año tras año. En Colombia, el Ministerio de Salud y Protección Social (2022) reporta que las enfermedades del sistema circulatorio son la primera causa de mortalidad general, con una tasa ajustada superior a 130 muertes por cada 100.000 habitantes.

El panorama se complica por hábitos cada vez más extendidos: sedentarismo, alimentación con exceso de sodio y grasas saturadas, tabaquismo, obesidad y altos niveles de estrés. A esto se suma que muchas personas ignoran su nivel de riesgo cardiovascular hasta que ocurre un evento agudo, típicamente un infarto o un accidente cerebrovascular, lo que reduce drásticamente las posibilidades de intervención preventiva.

Desde la ingeniería de sistemas existe una oportunidad concreta: construir un sistema que recoja los indicadores de estilo de vida que una persona puede registrar sin supervisión médica y los convierta en estimaciones de riesgo, pronósticos y alertas verificables. La aplicación web progresiva (PWA) es el medio de entrega elegido, porque ofrece la experiencia de una app nativa en cualquier navegador sin pasar por tiendas de aplicaciones.

La literatura científica respalda el uso de aprendizaje automático en este dominio. Weng et al. (2017) demostraron que los modelos de aprendizaje automático pueden superar a los algoritmos clínicos clásicos en la predicción de eventos cardiovasculares, y Krittanawong et al. (2020), en su meta-análisis, concluyen que las redes neuronales profundas y los métodos de ensemble alcanzan exactitudes superiores al 85 % a partir de datos clínicos estructurados. Esos desempeños se obtienen sobre variables de laboratorio que una aplicación de uso abierto no dispone, condición que delimita el alcance del presente trabajo y que se cuantifica en la Sección 8.

Un riesgo frecuente en los prototipos de salud digital actuales es confundir la integración de un modelo de lenguaje con capacidad predictiva. Un modelo generativo puede redactar una recomendación convincente, pero no estima ni valida nada, y cualquier proyección que escriba carece de respaldo numérico. Por ello este trabajo separa las dos funciones: un motor de predicción propio, auditable y evaluado contra benchmarks, calcula todas las cifras con su incertidumbre y su procedencia, y el modelo de lenguaje se limita a redactar sobre ellas.

Las Secciones 6, 7 y 8 describen el diseño del motor, los datos y el protocolo de evaluación, y los resultados.

2. PLANTEAMIENTO DEL PROBLEMA

Las enfermedades cardiovasculares son hoy el principal desafío de salud pública tanto a escala global como en Colombia. Según la OMS (2026a), causan cerca de 20,5 millones de muertes al año; las manifestaciones más frecuentes son hipertensión arterial, cardiopatía isquémica y accidente cerebrovascular, todas con tendencia ascendente en la última década.

Los factores de riesgo más prevalentes, sedentarismo, dietas con alto sodio y grasas saturadas, tabaquismo, obesidad y estrés crónico, atraviesan economías de todo nivel de ingreso. El problema operativo es que una gran parte de la población no conoce su riesgo cardiovascular hasta que aparece un evento clínico, porque no existen herramientas digitales gratuitas, accesibles y de alcance masivo que permitan una evaluación preventiva personalizada (Weng et al., 2017).

Desde la ingeniería de sistemas se identifican dos brechas. La primera es de acceso: las plataformas existentes suelen estar diseñadas para entornos hospitalarios y dependen de exámenes de laboratorio, como la presión arterial o el colesterol, que un usuario no aporta por su cuenta. La segunda es de rigor: las herramientas de uso abierto suelen ofrecer puntajes heurísticos sin evaluación y delegan la interpretación, e incluso la proyección del riesgo, en modelos de lenguaje. El propio prototipo de Pulso partía de esa situación: un puntaje calculado en el navegador sobre el último valor registrado de cada indicador, con umbrales fijos, y una proyección redactada por el modelo de lenguaje sin ningún cálculo que la respaldara.

Pregunta de Investigación

A partir de lo anterior, la pregunta que orienta este trabajo es:

¿De qué manera una Aplicación Web Progresiva impulsada por inteligencia artificial puede contribuir a la predicción, prevención y reducción del riesgo cardiovascular a nivel mundial mediante recomendaciones personalizadas de alimentación, ejercicio y vida saludable?

Para que la respuesta sea verificable, la pregunta se descompone en cuatro preguntas de ingeniería que la Sección 8 responde con mediciones:

- P1. ¿Los modelos de pronóstico ajustados sobre el historial de cada usuario superan a los benchmarks ingenuos, y con qué error?
- P2. ¿Con qué retraso y con cuántas falsas alarmas se detecta un cambio sostenido en un indicador?

- P3. ¿Cuánto discriminan, sobre datos poblacionales reales, los indicadores de estilo de vida que la aplicación captura, solos y junto con la edad y el sexo?
- P4. ¿Un índice construido con coeficientes de la literatura, sin entrenamiento, rinde como un modelo entrenado con esos mismos datos?

Antecedentes

La aplicación de inteligencia artificial al área cardiovascular cuenta con evidencia sólida. Weng et al. (2017) desarrollaron modelos de machine learning que predicen eventos cardiovasculares con mayor precisión que SCORE o el Framingham Risk Score. Krittanawong et al. (2020) confirman que las redes neuronales profundas y los métodos de ensemble superan el 85 % de exactitud sobre datos clínicos estructurados.

En prescripción de ejercicio, Liao et al. (2020) reportan que los sistemas de recomendación basados en aprendizaje automático mejoran significativamente la adherencia del paciente frente a planes genéricos. En nutrición computacional, Zeevi et al. (2015) demostraron que modelos de IA pueden estimar respuestas metabólicas individuales y proponer dietas ajustadas con resultados clínicamente significativos.

En pronóstico de series temporales, la práctica recomendada es contrastar todo modelo contra benchmarks simples, como repetir el último valor, la media o la tendencia lineal entre extremos, y medir el error de forma escalada para poder comparar series con unidades distintas; el MASE fue propuesto con ese fin (Hyndman & Koehler, 2006; Hyndman & Athanasopoulos, 2021). En detección de cambios, las cartas CUSUM (Page, 1954) y EWMA (Roberts, 1959) son el estándar del control estadístico de procesos para desvíos pequeños y sostenidos (Montgomery, 2019). En modelos de predicción clínica, la discriminación y la calibración deben reportarse juntas, porque un modelo puede ordenar bien a las personas y aun así asignarles probabilidades equivocadas (Van Calster et al., 2019).

En cuanto a la arquitectura, Biduski et al. (2020) muestran que las PWA presentan ventajas medibles sobre las apps nativas en contextos de salud pública: mejor accesibilidad sin pasar por una store, funcionamiento offline para zonas con conectividad intermitente, actualizaciones transparentes y un consumo de almacenamiento marcadamente menor. En el caso colombiano, Pinzón et al. (2020) y los informes del Observatorio Nacional de Salud (2021) han documentado barreras estructurales como la falta de tamizaje digital para población general, desigualdades regionales y baja adopción tecnológica en atención primaria.

3. JUSTIFICACIÓN

3.1 Relevancia Social

Las enfermedades cardiovasculares son también, y sobre todo, un indicador de desigualdad. Millones de personas en todo el mundo no cuentan con servicios de salud preventivos, y eso eleva la mortalidad por eventos que podrían haberse evitado. Pulso, como PWA gratuita y de alcance global, ayuda a reducir esa brecha: pone al alcance de cualquiera una estimación orientativa de su riesgo, la evolución proyectada de sus indicadores y una guía de hábitos adaptada a su contexto, sin exigir exámenes de laboratorio.

La elección de la arquitectura PWA es estratégica para países de ingresos medios y bajos, donde la conectividad es intermitente y la instalación desde una tienda de aplicaciones es una barrera adicional.

3.2 Relevancia Teórica

El proyecto se apoya en una literatura ya establecida sobre IA aplicada a la estratificación del riesgo (Weng et al., 2017; Krittanawong et al., 2020) y la extiende en tres direcciones medibles. Primera, cuantifica sobre datos poblacionales reales cuánto riesgo cardiovascular puede estimarse sin laboratorio: los indicadores de estilo de vida discriminan de forma limitada por sí solos (área bajo la curva ROC de 0,61), la edad y el sexo elevan esa cifra a 0,80, y aun así las variables de la aplicación aportan una mejora significativa sobre el modelo que solo usa edad y sexo. Segunda, aporta evidencia de que un índice construido con coeficientes de meta-análisis, sin entrenamiento, ordena a las personas prácticamente igual que un modelo entrenado sobre los mismos datos, lo que es relevante para cualquier herramienta preventiva que no dispone de datos etiquetados propios. Tercera, traslada al seguimiento personal de salud dos prácticas de otras disciplinas, la selección de modelos de pronóstico por backtesting contra benchmarks y las cartas de control estadístico, y documenta las decisiones que exigió adaptarlas a series cortas e irregulares.

3.3 Relevancia Práctica

Pulso permitirá a usuarios de cualquier país registrar sus indicadores de estilo de vida y obtener, calculado por el motor y no por un modelo de lenguaje:

- Un índice de riesgo modificable de 0 a 100, con los puntos que resta cada factor, la fuente bibliográfica de cada coeficiente y el multiplicador de contexto que aportan la edad y el sexo.

- El pronóstico a 30 días de cada indicador con intervalos de predicción del 80 % y el 95 %, el modelo que lo produjo y su error de backtesting.
- Alertas cuando un indicador cambia de forma sostenida, con la fecha estimada del cambio y su magnitud.
- La proyección del índice a 30 días, calculada sobre los pronósticos.
- Recomendaciones alimenticias, de vida saludable y de ejercicio redactadas a partir de esas cifras, con la instrucción explícita de no inventar números.
- Un dashboard con el historial, el pronóstico y la tabla de evaluación de los modelos, para que el usuario vea por qué el sistema dice lo que dice.

4. OBJETIVOS

4.1 Objetivo General

Desarrollar Pulso, una Aplicación Web Progresiva (PWA) basada en inteligencia artificial cuyo núcleo es un motor de predicción propio, entrenado y evaluado contra benchmarks sobre datos reales y sintéticos, para la estimación del riesgo cardiovascular, el pronóstico de los indicadores de estilo de vida y la detección de cambios sostenidos, integrado con recomendaciones de alimentación, vida saludable y ejercicio, y orientado a la prevención cardiovascular a nivel mundial.

4.2 Objetivos Específicos

- Diseñar la arquitectura de Pulso como PWA y, dentro de ella, un motor de predicción desacoplado de la interfaz y de los servicios de IA generativa, cuyos modelos, umbrales y coeficientes estén sustentados en la literatura y cuyas salidas incluyan siempre incertidumbre y procedencia.
- Implementar desde cero los componentes del motor: pronóstico de series temporales con selección por backtesting contra benchmarks, índice de riesgo modificable con atribución por factor, detección de cambios sostenidos y un módulo de aprendizaje supervisado; e integrarlos con los módulos funcionales de recomendaciones, rutinas y seguimiento.
- Entrenar y evaluar el estimador de riesgo sobre datos poblacionales reales con métricas de discriminación y calibración, validación cruzada estratificada repetida y comparación contra benchmarks; evaluar el pronóstico y la detección sobre cohortes sintéticas con parámetros conocidos; y verificar la implementación contra una referencia independiente.
- Validar el prototipo mediante pruebas de usabilidad con usuarios representativos, la revisión de un profesional de salud y la verificación del funcionamiento en distintos dispositivos y condiciones de conectividad.

5. ALCANCE Y LIMITACIONES

5.1 Alcance

El proyecto contempla el desarrollo de Pulso como una PWA de alcance global, basada en inteligencia artificial, orientada a la estimación del riesgo cardiovascular, la generación de recomendaciones alimenticias con ingredientes específicos, planes de vida saludable, rutinas de ejercicio personalizadas y el seguimiento continuo del estado de salud del usuario. La plataforma estará disponible para cualquier persona con navegador compatible, será instalable en móvil, tablet o desktop, funcionará offline mediante Service Workers y enviará notificaciones push para alertas preventivas. El sistema integra seis módulos funcionales:

1. Ingreso de indicadores de estilo de vida (frecuencia cardíaca en reposo, peso, horas de sueño y nivel de estrés) asociado a un identificador anónimo generado en el propio dispositivo, y un perfil opcional con edad, sexo, altura y tabaquismo, sin registro de usuario ni datos personales identificables.
2. Motor de predicción, descrito en la Sección 6: pronóstico de cada indicador, índice de riesgo modificable con atribución por factor, contexto de edad y sexo, proyección del índice y detección de cambios sostenidos. Reemplaza al puntaje heurístico de la versión inicial del prototipo y es la única fuente de las cifras que muestra la aplicación.
3. Recomendaciones alimenticias personalizadas con ingredientes, cantidades, métodos de preparación, alternativas regionales y planes semanales con lista de compras automatizada.
4. Recomendaciones de vida saludable que abarcan manejo del estrés, calidad del sueño, hidratación y hábitos cotidianos.
5. Rutinas de ejercicio adaptadas al nivel de riesgo con progresividad automática y alertas de seguridad.
6. Sistema de seguimiento con dashboard interactivo que muestra el historial, el pronóstico con sus intervalos, el modelo seleccionado y las alertas, y reportes periódicos exportables en PDF.

5.2 Limitaciones

El proyecto presenta varias limitaciones que conviene declarar de entrada. El desarrollo se limita a un prototipo funcional en fase experimental, sin implementación directa en insti-

tuciones médicas. Las recomendaciones generadas son de carácter orientativo y no sustituyen el criterio del profesional de salud, y la exactitud de las estimaciones está condicionada por la calidad y veracidad de los datos que ingrese el usuario, dado que el sistema no cuenta con verificación clínica directa.

El índice no es una escala clínica. Sus coeficientes provienen de la literatura, pero la combinación, la forma de las curvas entre los puntos citados y la normalización son decisiones del proyecto. No estima probabilidades absolutas de un evento y no reemplaza ecuaciones validadas como Framingham, que requieren presión arterial y colesterol, variables que la aplicación no solicita por decisión de diseño.

Sobre los conjuntos de datos. La fuente de entrenamiento y evaluación del estimador es NHANES 2021-2023 (CDC, 2024), el único conjunto de acceso público que mide las mismas variables que la aplicación captura. El UCI Heart Disease (Janosi et al., 1988) es de acceso abierto y fue verificado: su subconjunto usable, `processed.cleveland.data`, contiene 303 registros y 14 variables, de los cuales 6 presentan valores faltantes. Comparte con la aplicación solo la edad y el sexo, y su frecuencia cardíaca es la máxima alcanzada en prueba de esfuerzo, no la de reposo; por eso se usa para validar la implementación de los algoritmos y no como fuente del estimador. El Framingham Heart Study (Dawber et al., 1951) no es de descarga libre: su acceso se tramita ante el repositorio BioLINCC del National Heart, Lung, and Blood Institute y exige aprobación de un comité de ética y un acuerdo formal de uso de datos, plazos incompatibles con el cronograma del trabajo. El Global Health Observatory de la OMS (2026b) publica indicadores agregados por país y no registros individuales, por lo que sustenta las cifras epidemiológicas de contexto pero no permite entrenar un estimador individual.

Restricciones de NHANES. Condicionan la interpretación de la Sección 8.3 y se declaran de manera explícita. Primera: el diseño de la encuesta es transversal, de modo que el modelo estima la asociación entre el estado actual del participante y el antecedente de un evento cardiovascular, no la incidencia futura; el prototipo no realiza predicción prospectiva de eventos. Segunda: el estrés se aproximó con el cuestionario PHQ-9 (Kroenke et al., 2001), que mide síntomas depresivos y no estrés percibido, porque el ciclo no incluye una escala de estrés. Tercera: el desenlace es autorreportado y no se verificó contra historia clínica. Cuarta: se omitieron los ponderadores de muestreo complejo, lo que es admisible para evaluar un clasificador pero impide generar estimaciones poblacionales. Quinta: NHANES describe a la población de los Estados Unidos; la transferencia a población colombiana requiere validación externa y recalibración, que queda planteada como línea de trabajo posterior.

Sobre la evaluación sintética. Demuestra que la implementación es correcta y describe su comportamiento frente a patrones conocidos, pero no mide el desempeño sobre usuarios

reales, para lo cual no existe todavía un historial suficiente. Un conjunto público de series de dispositivos portátiles sería la fuente natural para esa evaluación.

6. DISEÑO DEL MOTOR DE PREDICCIÓN

6.1 Principios de Diseño

El motor se construyó bajo cuatro reglas que se verifican en el código y en las pruebas automatizadas:


- **Pureza.** El módulo `src/lib/ml` no depende de la base de datos, de la interfaz ni del framework web. Se compila por separado y se ejecuta en segundos, lo que permite probarlo y evaluarlo sin levantar la aplicación.
- **Incertidumbre y procedencia en toda salida.** Cada pronóstico lleva intervalos del 80 % y el 95 %, y cada cifra del informe indica qué modelo la produjo, con qué error de backtesting y con qué nivel de confianza.
- **Los benchmarks compiten en igualdad.** Los modelos ingenuos implementan la misma interfaz que los demás y participan en la selección: un modelo más complejo solo se usa si gana en backtesting.
- **Degradación explícita.** Con pocos datos el motor lo declara (confianza baja, factor excluido, índice insuficiente) en lugar de extrapolar.

6.2 Arquitectura

La Figura 1 resume el flujo. Los registros diarios se convierten en una serie por indicador; sobre cada serie se seleccionan y ajustan los modelos de pronóstico y se aplican las cartas de control; con los niveles actuales y el perfil se calcula el índice, y con los pronósticos, su proyección. El resultado es un informe serializable que consumen la interfaz y el modelo de lenguaje. El entrenamiento y la evaluación se ejecutan fuera de línea, con scripts reproducibles del mismo repositorio.

6.3 Preparación de las Series

Cada indicador se representa como una grilla diaria continua desde el primer registro hasta la fecha actual; los días sin registro quedan vacíos, porque la aplicación no obliga a registrar todos los días. La regresión lineal, Theil-Sen y los benchmarks trabajan directamente sobre los días observados. Holt y Holt-Winters exigen una grilla regular: para ellos se interpolan linealmente los huecos interiores de hasta tres días, y si más del 40 % de los puntos serían imputados, esos modelos no compiten en esa serie. El nivel actual de cada

Figura 1. *Arquitectura del motor de predicción y su integración con la aplicación*

Nota. Las cajas sombreadas forman el motor (`src/lib/ml`). El pronóstico de cada indicador alimenta también la proyección del índice. El modelo de lenguaje recibe el informe ya calculado y no produce cifras. El entrenamiento y la evaluación se ejecutan fuera de línea.

indicador, que alimenta el índice, es la mediana de los últimos siete días, para que una noche atípica no lo altere.

6.4 Modelos de Pronóstico y Selección por Backtesting

El motor ajusta los ocho modelos de la Tabla 1, todos con la misma interfaz: ajustan sobre el historial y devuelven la media del pronóstico y su desvío a cada horizonte h , con el que se construyen los intervalos del 80 % y el 95 % (Hyndman & Athanasopoulos, 2021). Los cuatro primeros son los benchmarks. Theil-Sen (Theil, 1950; Sen, 1968) usa la mediana de las pendientes entre todos los pares de puntos, de modo que un registro atípico no la desvíe. Holt (Holt, 2004) incorpora un parámetro de amortiguación ϕ (Gardner & McKenzie, 1985) para que la tendencia no se extrapole indefinidamente, y Holt-Winters (Winters, 1960) agrega un patrón semanal. Los parámetros α , β^* y ϕ se eligen por búsqueda en grilla minimizando el error a un paso. Los cuantiles de la normal y de la t de Student que definen los intervalos se calculan con aproximaciones numéricas estándar (Abramowitz & Stegun, 1964).

Backtesting. Para cada serie se usa un esquema de origen móvil con ventana expansiva: en cada día de origen o con al menos 14 observaciones previas, cada modelo se ajusta con lo observado antes de o y pronostica los siete días siguientes, que se comparan solo contra los días con registro real. Nunca se usa validación cruzada aleatoria, porque mezclaría el futuro con el pasado. La métrica de selección es el error absoluto escalado medio (Hyndman

Tabla 1. *Modelos de pronóstico implementados*

Modelo	Pronóstico a h pasos	Desvío del error σ_h	n mín.
Naïve	y_n	$\sigma\sqrt{h}$	2
Media móvil ($k = 7$)	media de los últimos k registros	$\sigma\sqrt{1 + 1/k}$	3
Drift	$y_n + h \frac{y_n - y_1}{t_n - t_1}$	$\sigma\sqrt{h(1 + h/(n-1))}$	3
Naïve estacional ($m = 7$)	mismo día de la semana anterior	$\sigma\sqrt{[(h-1)/m] + 1}$	8
Regresión lineal (OLS)	$a + b t_{n+h}$	$s\sqrt{1 + \frac{1}{n} + \frac{(t_{n+h} - \bar{t})^2}{S_{tt}}}$, cuantil t con $n - 2$ gl	5
Theil-Sen	$\tilde{a} + \tilde{b} t_{n+h}$	como OLS, con sus propios residuos	5
Holt amortiguado	$\ell_n + (\phi + \dots + \phi^h) b_n$	$\sigma\sqrt{1 + \sum_{j=1}^{h-1} (\alpha + \alpha\beta^*\phi_j)^2}$	10
Holt-Winters aditivo ($m = 7$)	$\ell_n + h b_n + s_{n+h-m(k+1)}$	fórmula de Hyndman y Athanasopoulos (2021, § 8.7)	21

Nota. σ es el desvío de los residuos a un paso; $\phi_j = \phi + \dots + \phi^j$; $k = \lfloor (h-1)/m \rfloor$ en Holt-Winters. Los cuatro primeros modelos son los benchmarks.

& Koehler, 2006):

$$\text{MASE}_o = \frac{\frac{1}{H} \sum_{h=1}^H |y_{o+h} - \hat{y}_{o+h}|}{\frac{1}{o-1} \sum_{t=2}^o |y_t - y_{t-1}|},$$

es decir, el error del modelo dividido por el error del pronóstico ingenuo dentro del entrenamiento: un valor menor que 1 significa que el modelo supera a repetir el último valor. Se reportan además MAE, RMSE y la cobertura empírica de los intervalos, que en un intervalo honesto del 80 % debe rondar el 80 %.

Selección. Gana el menor MASE entre los modelos con al menos cinco pronósticos evaluados; ante empate, el más simple. Con menos de 21 registros no se compara y se usa la media móvil con confianza baja. La confianza es alta con 45 registros o más y MASE menor que 0,9, y media con 21 o más.

6.5 Índice de Riesgo Modificable

Para cada factor modificable i con valor x_i , la función $\ell_i(x_i) \geq 0$ es el logaritmo del riesgo relativo respecto de un rango de referencia, en el que vale cero, y es continua, de modo que dormir cinco horas pesa proporcionalmente más que dormir seis. Bajo el supuesto multiplicativo de los modelos log-lineales, el índice combina los factores con datos así:

$$L = \sum_i \ell_i(x_i), \quad \text{RR} = e^L, \quad L_{\text{máx}} = \sum_i \ell_i(x_i^{\text{peor}}), \quad \text{score} = 100 \left(1 - \frac{L}{L_{\text{máx}}} \right).$$

Como el puntaje es lineal en L , los puntos que resta cada factor son exactos y aditivos, $100 \ell_i / L_{\max}$, y la interfaz puede mostrarlos sin métodos de atribución adicionales. La Tabla 2 presenta las funciones y sus fuentes. Un factor sin datos se excluye de L y de $L_{\max}$, y con menos de dos factores el índice se declara insuficiente.

Tabla 2. Factores del índice, funciones de log-riesgo relativo y fuentes

Factor	Referencia	$\ell_i(x)$ fuera de la referencia	Fuente
FC en reposo	50–70 lpm	$\ln(1,09) \frac{\min(x,120)-70}{10}$ sobre 70; $\ln(1,10) \frac{50-\max(x,35)}{10}$ bajo 50 (evidencia débil)	Zhang et al. (2016); Aune et al. (2017)
Sueño	7–8 h	$\frac{\ln 1,48}{2} (7 - \max(x, 3))$ bajo 7; $\frac{\ln 1,38}{2} (\min(x, 12) - 8)$ sobre 8	Cappuccio et al. (2011); Yin et al. (2017)
Estrés (1–10)	hasta 3	$\ln(1,27) \frac{\min(x,10)-3}{7}$ (evidencia débil: escala autorreportada)	Richardson et al. (2012)
IMC	18,5–25	$\ln(1,39) \frac{\min(x,40)-25}{5}$ sobre 25; $\ln(1,3) \frac{18,5-\max(x,15)}{3,5}$ bajo 18,5 (evidencia débil)	Global BMI Mortality Collaboration (2016)
Tabaquismo	no fuma	$\ln 2,5$ si fuma actualmente	Yusuf et al. (2004)

Nota. La curva de sueño está calibrada para valer $\ln 1,48$ con 5 horas y $\ln 1,38$ con 10 horas, los riesgos relativos de sueño corto y largo del meta-análisis citado.

Contexto no modificable. La edad y el sexo no entran al puntaje, para que refleje solo lo que la persona puede cambiar: alguien de 70 años con hábitos excelentes no debe aparecer en riesgo por su edad. Se reportan aparte como un multiplicador de contexto $e^{\ell_{\text{edad}} + \ell_{\text{sexo}}}$, con $\ell_{\text{edad}} = \frac{\ln 2}{10} (\min(e, 90) - 40)$ para edades mayores de 40 años, que expresa la duplicación aproximada del riesgo por década, y $\ell_{\text{sexo}} = \ln 1,5$ para el sexo masculino. La Sección 8.3 contrasta ambos valores con los que aprende un modelo entrenado.

Proyección. El mismo índice se evalúa sobre el pronóstico a 30 días de cada indicador. Como las funciones tienen forma de U, el intervalo del puntaje proyectado se obtiene evaluando todas las combinaciones de extremos de los intervalos del 80 % (2^k evaluaciones con $k \leq 4$). La proyección deja así de ser un texto del modelo de lenguaje.

6.6 Detección de Cambios Sostenidos

Sobre cada indicador se estandariza $z_t = (y_t - \hat{\mu})/\hat{\sigma}$ con una línea base personal y se aplican dos cartas de control con los parámetros estándar de Montgomery (2019):

$$S_t^+ = \max(0, S_{t-1}^+ + z_t - k), \quad S_t^- = \max(0, S_{t-1}^- - z_t - k), \\ k = 0,5, \quad \text{alarma si } S_t^\pm > h = 5;$$

$$Z_t = \lambda y_t + (1 - \lambda)Z_{t-1}, \quad \text{límites } \hat{\mu} \pm L\hat{\sigma}\sqrt{\frac{\lambda}{2-\lambda}(1 - (1 - \lambda)^{2t})}, \quad \lambda = 0,2, \quad L = 3.$$

CUSUM (Page, 1954) acumula desvíos pequeños y persistentes, como un aumento de ocho latidos que se mantiene, que un umbral sobre valores individuales no detecta; el día del cambio se estima como el último en que el acumulado valía cero. EWMA (Roberts, 1959) funciona como verificación independiente. La evaluación obligó a tres decisiones que no están en el manual. La línea base es auto-iniciada (Hawkins, 1987): arranca con 14 observaciones y sigue incorporando todas las siguientes, con media y varianza actualizadas por el método de Welford (1962), hasta la primera alarma, cuando se congela; la primera versión, con la base fija en 14 observaciones, disparaba 22 alarmas en 12 series estables. Los valores estandarizados se winsorizan en ± 3 para que un atípico aislado no cargue la carta de una vez (Hawkins & Olwell, 1998). Y las alarmas consecutivas de un mismo desvío se consolidan en una sola alerta con fecha de inicio, de detección y de última confirmación. Con menos de 15 registros no se emiten alertas.

6.7 Módulo de Aprendizaje Supervisado

Para entrenar y validar el estimador con datos etiquetados se implementaron, también desde cero y siguiendo la formulación de Hastie et al. (2009), los siguientes componentes:

- **Regresión logística** ajustada por mínimos cuadrados reponderados iterativamente (IRLS, método de Newton-Raphson), con una penalización ridge pequeña, $\lambda = 0,01$, que garantiza que la hessiana sea invertible sin penalizar el intercepto (le Cessie & van Houwelingen, 1992). En cada iteración,

$$\beta \leftarrow \beta + \left(X^\top W X + \lambda \tilde{I}\right)^{-1} \left(X^\top (y - p) - \lambda \tilde{\beta}\right), \quad W = \text{diag}(p_i(1 - p_i)),$$

y los errores estándar salen de la diagonal de la inversa de la hessiana en el óptimo. Las variables se estandarizan con los estadísticos de cada partición de entrenamiento, nunca con los de prueba.

- **Gradient boosting** con árboles de regresión (Friedman, 2001): parte del logaritmo de la odds de la prevalencia y en cada ronda ajusta un árbol de profundidad 3 al gradiente negativo de la log-verosimilitud, con un paso de Newton por hoja y tasa de aprendizaje $\nu = 0,1$, durante 100 rondas.
- **k vecinos más cercanos** (Cover & Hart, 1967) con distancia euclídea sobre variables estandarizadas, como comparador no paramétrico.
- **Métricas:** área bajo la curva ROC por el estadístico de Mann-Whitney (Hanley & McNeil, 1982), puntaje de Brier, log-verosimilitud, diagrama de calibración, umbral de Youden (1950) y validación cruzada estratificada reproducible con semilla.
- **Lector del formato SAS Transport (XPORT) versión 5**, en el que el CDC publica los archivos de NHANES, con la conversión de los números en coma flotante IBM de base 16 y de los valores faltantes de SAS.

6.8 Integración con la Aplicación y con el Modelo de Lenguaje

El motor entra a la aplicación por un único punto: una acción de servidor que carga 90 días de registros, el perfil y la adherencia a hábitos, y devuelve el informe. La pantalla del índice muestra el puntaje, los puntos que resta cada factor con su fuente, el contexto, la proyección con su intervalo y los cambios detectados; el dashboard dibuja el pronóstico con sus bandas y la tabla de backtesting del indicador seleccionado. Las tres rutas que usan un modelo de lenguaje reciben únicamente el identificador del usuario; el servidor calcula el informe y le entrega al modelo un resumen textual con todas las cifras y su procedencia, con la instrucción de no inventar números ni proyecciones: ninguna cifra que muestra la aplicación proviene de él.

6.9 Verificación del Software

El motor cuenta con 70 pruebas automatizadas, cada una contra un valor conocido y no contra una salida guardada: por ejemplo, que el MASE del pronóstico ingenuo dentro de la muestra valga exactamente 1, que Theil-Sen no se desvíe ante un atípico que sí desvía a la regresión lineal, que CUSUM detecte un salto de tres desvíos en pocas observaciones, que el gradient boosting aprenda una interacción que la regresión logística no puede representar o que el lector XPORT decodifique valores de coma flotante IBM conocidos. Además, la regresión logística se reimplementó de forma independiente en numpy sobre los mismos datos (Sección 8.4). Todas las corridas usan semillas fijas y se reproducen con los comandos del Anexo A.

7. DATOS Y PROTOCOLO DE ENTRENAMIENTO Y EVALUACIÓN

7.1 Cohorte Sintética con Parámetros Conocidos

No existe un historial real de usuarios con el cual evaluar el pronóstico y la detección, y aunque existiera no se conocería el patrón verdadero contra el cual medir. Por eso se generó una cohorte con parámetros conocidos y semilla fija: para cada uno de los cuatro indicadores, siete perfiles de 90 días con rangos fisiológicos y un 15 % de días sin registro, descritos en la Tabla 3, para un total de 28 series.

Tabla 3. *Perfiles de la cohorte sintética*

Perfil	Patrón generado
Estable	Solo ruido alrededor de un nivel.
Tendencia suave y fuerte	Deriva lineal (por ejemplo, frecuencia cardíaca +0,05 y +0,15 lpm por día).
Estacional	Patrón semanal (por ejemplo, sueño +1,2 h los domingos y +0,9 h los sábados).
Cambio de régimen	Salto sostenido el día 45: frecuencia cardíaca +8 lpm, sueño −1,2 h, estrés +3, peso +2,5 kg.
Ruidoso	Desvío doble y 5 % de valores atípicos gruesos.
Disperso	40 % de días sin registro y deriva suave.

7.2 Muestra Analítica de NHANES 2021-2023

La muestra se construyó con siete archivos del ciclo agosto 2021 – agosto 2023 (CDC, 2024), cruzados por identificador de participante y leídos con el lector XPORT propio. La Tabla 4 muestra el flujo de exclusiones y la Tabla 5, la correspondencia entre las variables de la aplicación y las de la encuesta. El desenlace vale 1 si el participante respondió afirmativamente a alguna de las cinco preguntas de antecedente cardiovascular y 0 si ninguna fue afirmativa y al menos una fue negativa. El resultado son **5.043 adultos con 597 casos positivos (11,8 %)**, cuya caracterización aparece en la Tabla 6.

7.3 UCI Heart Disease

El subconjunto Cleveland del UCI Heart Disease (Janosi et al., 1988; Detrano et al., 1989) se usa para validar la implementación del módulo supervisado. Tras descartar seis registros con faltantes quedan 297 pacientes derivados a evaluación cardiológica, 137 de ellos con enfermedad coronaria (46,1 %), y 13 variables clínicas.

Tabla 4. *Flujo de construcción de la muestra analítica de NHANES 2021-2023*

Criterio	Participantes
Participantes del ciclo (archivo demográfico)	11.933
Adultos de 18 años o más	8.153
Con pulso en reposo medido	6.123
Con peso e índice de masa corporal medidos	6.061
Con horas de sueño reportadas	6.003
Con los nueve ítems del PHQ-9 respondidos	5.282
Con desenlace cardiovascular conocido (muestra analítica)	5.043

Tabla 5. *Correspondencia entre las variables de la aplicación y las de NHANES*

Aplicación	NHANES	Observación
FC en reposo	BPX0PLS1	Pulso de la primera lectura oscilométrica, tras cinco minutos de reposo sentado.
Peso e IMC	BMXWT, BMXBMI	Medidos en el centro de examen, no autorreportados. En la aplicación el IMC sale del peso y de la altura del perfil.
Horas de sueño	SLD012	Horas de sueño en días laborables.
Estrés (1–10)	PHQ-9 (DPQ010–DPQ090)	Puntaje total de 0 a 27, llevado a la escala de la aplicación como redondeo($1 + 9 \cdot \text{PHQ}/27$). Es una aproximación.
Tabaquismo	SMQ020, SMQ040	Fumador actual: al menos 100 cigarrillos en la vida y fuma todos o algunos días. Desconocido en 7 participantes, codificados como no fumadores.
Edad y sexo	RIDAGEYR, RIAGENDR	La encuesta agrupa en 80 las edades de 80 años o más.
Desenlace	MCQ160B–MCQ160F	Falla cardíaca, enfermedad coronaria, angina, infarto o accidente cerebrovascular, autorreportados.

Tabla 6. *Caracterización de la muestra analítica según el antecedente cardiovascular*

Variable	Total (<i>n</i> = 5.043)	Con antecedente (<i>n</i> = 597)	Sin antecedente (<i>n</i> = 4.446)
Edad (años)	53,6 ± 17,0	66,8 ± 10,8	51,8 ± 17,0
Hombres	45,4 %	56,3 %	43,9 %
FC en reposo (lpm)	70,8 ± 12,3	70,8 ± 13,8	70,7 ± 12,0
IMC (kg/m ²)	29,7 ± 7,1	31,6 ± 7,6	29,5 ± 7,0
Peso (kg)	83,5 ± 21,8	88,5 ± 23,1	82,9 ± 21,6
Sueño (h)	7,7 ± 1,5	7,9 ± 1,9	7,6 ± 1,5
PHQ-9 (0–27)	4,0 ± 4,6	4,8 ± 5,0	3,9 ± 4,6
Fumador actual	14,5 %	19,1 %	13,8 %

Nota. Media ± desvío estándar; proporción en las variables binarias.

7.4 Protocolo de Evaluación

Pronóstico y detección. Para cada una de las 28 series sintéticas se ejecuta la selección completa, es decir, el backtesting de los ocho modelos con horizonte de siete días; se mide cuánto se acercan las pendientes estimadas a la pendiente real y, en los perfiles con cambio de régimen, el retraso entre el cambio verdadero y la primera alerta de cada carta. Las falsas alarmas se cuentan en los perfiles estable y ruidoso.

Estimador de riesgo. Todos los modelos se evalúan sobre las mismas particiones: validación cruzada estratificada de cinco particiones repetida diez veces con semillas distintas, es decir, 50 evaluaciones fuera de muestra por modelo, de las que se reportan media y desvío. Se comparan tres familias: benchmarks (la prevalencia, que no discrimina, y una regresión logística con solo edad y sexo); puntajes sin entrenamiento (el puntaje heurístico de la versión inicial del prototipo, que asignaba 35, 35 y 30 puntos a frecuencia cardíaca, sueño y estrés multiplicados por 1, 0,55 o 0,15 según su estado, y el índice del motor, solo y combinado con su contexto de edad y sexo); y modelos entrenados (regresión logística, gradient boosting y k vecinos, con $k = 65 \approx \sqrt{n}$ de entrenamiento). Sobre las predicciones fuera de muestra de la primera repetición se calculan la curva ROC, la calibración por deciles, el umbral de Youden y las diferencias de área bajo la curva entre pares de modelos, con intervalos de confianza del 95 % por bootstrap pareado de 2.000 remuestreos (Efron & Tibshirani, 1993). Los hiperparámetros de gradient boosting y de k vecinos no se optimizaron: se usan como comparadores con valores estándar.

Implementación. En UCI se repite el mismo protocolo de validación cruzada con tres conjuntos de variables, y los coeficientes de la regresión logística ajustada a toda la muestra, tanto en UCI como en NHANES, se comparan con los de la implementación independiente en numpy.

8. RESULTADOS

8.1 Pronóstico Frente a Benchmarks

La Tabla 7 resume el backtesting sobre las 28 series. El modelo que el motor selecciona supera al pronóstico ingenuo (MASE menor que 1) en **23 de las 28 series**, y en 20 de ellas el elegido no es un benchmark. Las series restantes son aquellas en las que el ruido domina y un benchmark es, honestamente, lo mejor disponible; el motor lo reconoce en lugar de forzar un modelo complejo. La media móvil es un benchmark exigente: su MASE medio iguala al de la regresión lineal y al de Theil-Sen, y gana en 8 series, entre ellas las tres estables de frecuencia cardíaca, sueño y peso. La cobertura empírica media de los intervalos del 80 % está entre el 74 % y el 81 % en los modelos que no son el naïve ni el drift; esos dos cubren el 93 %, es decir, sus intervalos son demasiado anchos, una de las razones por las que pierden.

Tabla 7. *Desempeño de los modelos de pronóstico en la cohorte sintética*


Modelo	MASE medio	MASE mediana	Cobertura IC 80 %	Series ganadas
Naïve (benchmark)	1,11	1,10	93 %	0
Media móvil de 7 días (benchmark)	0,88	0,87	81 %	8
Drift (benchmark)	1,17	1,13	93 %	0
Naïve estacional (benchmark)	1,11	1,07	78 %	0
Regresión lineal (OLS)	0,88	0,86	78 %	8
Theil-Sen	0,88	0,86	78 %	6
Holt amortiguado	0,90	0,87	74 %	5
Holt-Winters semanal	1,04	1,01	80 %	1

Nota. Backtesting de origen móvil con horizonte de 7 días, semilla 42. Holt y Holt-Winters compiten en 27 series porque en una serie dispersa la fracción imputada supera el 40 %.


Los modelos también recuperan los parámetros verdaderos. En las series con tendencia, la regresión lineal y Theil-Sen estiman la pendiente real con un error del orden del ruido: en peso con tendencia fuerte, la pendiente real de $-0,080$ kg por día se estima en $-0,080$ con ambos métodos, y en frecuencia cardíaca con tendencia fuerte, la real de $0,150$ lpm por día se estima en $0,160$ y $0,167$. Holt-Winters recupera la amplitud semanal verdadera, por ejemplo $1,76$ horas frente a $1,60$ en sueño y $2,23$ frente a $2,30$ en estrés (Figura 3).

8.2 Detección de Cambios Sostenidos

Las dos cartas detectan los cuatro cambios de régimen (Tabla 8): CUSUM con un retraso medio de **4,5 días** y EWMA de **5,8 días**. En los perfiles estable y ruidoso se registraron 5 falsas alarmas en 8 series de 90 días, 0,6 por serie, y el perfil ruidoso incluye a propósito

Figura 2. *Error de pronóstico por modelo relativo al pronóstico ingenuo*

Nota. MASE medio en las 28 series; los benchmarks aparecen en gris. La línea discontinua marca MASE = 1.

Figura 3. *Pendiente estimada frente a pendiente real en las series con tendencia*


Nota. Pendientes normalizadas por el desvío del ruido de cada serie. La diagonal representa la estimación perfecta.

atípicos de ± 5 desvíos. Las series con tendencia también disparan alertas, lo que es correcto: una deriva sostenida es un cambio de régimen. Las cartas no modelan el patrón semanal; en los cuatro perfiles estacionales no hubo alertas, pero un fin de semana muy distinto del resto podría dispararlas, y esa limitación se declara. La Figura 4 ilustra el funcionamiento de CUSUM sobre una serie con un salto conocido.

Tabla 8. Retraso de detección del cambio de régimen por indicador

Indicador	Salto introducido	Retraso CUSUM	Retraso EWMA
Frecuencia cardíaca	+8 lpm	5 días	5 días
Horas de sueño	-1,2 h	9 días	12 días
Nivel de estrés	+3 puntos	2 días	4 días
Peso	+2,5 kg	2 días	2 días
Media		4,5 días	5,8 días

Figura 4. Detección de un desvío sostenido de la frecuencia cardíaca con CUSUM



Nota. Serie sintética de 60 días con un salto de +8 lpm el día 30. Arriba, los registros y el nivel real; abajo, el estadístico acumulado S^+ y el umbral $h = 5$.


8.3 Estimador de Riesgo sobre NHANES

La Tabla 9 y la Figura 5 presentan el desempeño de los once modelos sobre las mismas 50 particiones de prueba, y la Tabla 10 contrasta los pares que responden a las preguntas P3 y P4.

Tabla 9. *Discriminación del antecedente cardiovascular en NHANES 2021-2023*

Modelo	Variables	AUC	Brier
<i>Benchmarks</i>			
Prevalencia	ninguna	0,500 $\pm$ 0,000	0,104
Regresión logística	edad y sexo	0,769 $\pm$ 0,013	0,094
<i>Sin entrenamiento</i>			
Heurística inicial	FC, sueño, estrés	0,564 $\pm$ 0,026	—
Índice del motor	FC, sueño, estrés, IMC, tabaco	0,611 $\pm$ 0,025	—
Índice del motor + contexto	índice, edad y sexo	0,799 $\pm$ 0,015	—
<i>Entrenados sobre NHANES</i>			
Regresión logística	estilo de vida (5)	0,608 $\pm$ 0,025	0,103
Gradient boosting	estilo de vida (5)	0,605 $\pm$ 0,025	0,105
Regresión logística	estilo de vida, edad y sexo (7)	0,805 $\pm$ 0,014	0,091
Regresión logística	los 7 log RR del motor	0,801 $\pm$ 0,015	0,092
Gradient boosting	estilo de vida, edad y sexo (7)	0,794 $\pm$ 0,016	0,093
k vecinos ($k = 65$)	estilo de vida, edad y sexo (7)	0,775 $\pm$ 0,017	0,094

Nota. AUC: área bajo la curva ROC, media $\pm$ desvío sobre 50 particiones de prueba (validación cruzada estratificada 5×10 , $n = 5.043$). Brier: error cuadrático medio de la probabilidad, solo para los modelos que la producen. El estilo de vida comprende frecuencia cardíaca, IMC, sueño, PHQ-9 y tabaquismo. El índice sin entrenamiento se evalúa por su orden: a mayor riesgo relativo, mayor riesgo.

Figura 5. *Área bajo la curva ROC de todos los modelos sobre NHANES*

Nota. Media $\pm$ desvío sobre 50 particiones de prueba. En azul los modelos entrenados, en naranja los puntajes sin entrenamiento y en gris los benchmarks.

Tabla 10. *Diferencias de área bajo la curva entre pares de modelos*

Comparación	ΔAUC	IC 95 %
Índice del motor frente a la heurística inicial	+0,046	[0,016; 0,075]
Logística con estilo de vida frente al índice del motor	−0,001	[−0,022; 0,019]
Logística con estilo de vida, edad y sexo frente a solo edad y sexo	+0,037	[0,025; 0,049]
Logística con estilo de vida, edad y sexo frente al índice + contexto	+0,007	[−0,001; 0,015]
Gradient boosting frente a logística, ambos con 7 variables	−0,010	[−0,018; −0,001]

Nota. Diferencia sobre las predicciones fuera de muestra de la primera repetición; intervalo por bootstrap pareado de 2.000 remuestreos. Un intervalo que no contiene el cero indica una diferencia significativa al 5 %.


Los indicadores de estilo de vida discriminan poco por sí solos. Con las cinco variables modificables, el mejor modelo alcanza un AUC de 0,61. La frecuencia cardíaca en reposo, por ejemplo, tiene la misma media en quienes tienen antecedente y en quienes no lo tienen (70,8 y 70,7 lpm, Tabla 6). Aun así, el índice del motor ordena mejor que la heurística inicial ($\Delta\text{AUC} = +0,046$, intervalo que excluye el cero), lo que confirma empíricamente el reemplazo de los umbrales fijos por funciones continuas y la incorporación del IMC y del tabaquismo.

Entrenar no mejora al índice de la literatura (P4). Una regresión logística entrenada con las mismas variables obtiene 0,608 frente a 0,611 del índice, una diferencia de −0,001 con un intervalo centrado en cero. Con edad y sexo, el índice combinado con su contexto alcanza 0,799 y la regresión logística entrenada 0,805: la ventaja de 0,007 no es significativa al 5 %. El índice, construido solo con coeficientes publicados y sin ver estos datos, ordena a las personas prácticamente igual que el mejor modelo entrenado.

Edad y sexo son el factor decisivo, pero no el único (P3). La regresión logística con solo edad y sexo ya alcanza 0,769; agregar las cinco variables de estilo de vida la lleva a 0,805, una mejora de 0,037 con un intervalo de [0,025; 0,049]. Las variables que la aplicación captura sí aportan información por encima de la demografía. Esto motivó la incorporación del perfil opcional con edad y sexo.

La relación es esencialmente lineal. El gradient boosting no supera a la regresión logística; con siete variables queda 0,010 por debajo, diferencia significativa, y k vecinos queda en 0,775. No hay evidencia de interacciones o no linealidades que justifiquen un modelo más flexible, y la regresión logística tiene la ventaja de producir coeficientes interpretables.

Calibración y punto de operación. Las probabilidades de la regresión logística de referencia, con estilo de vida, edad y sexo, están bien calibradas (Figura 7): la pendiente de calibración es 0,99 y el intercepto −0,02, frente a los valores ideales de 1 y 0, y el riesgo medio predicho coincide con la prevalencia observada, 11,8 %. El puntaje de Brier baja de 0,104 con la prevalencia a 0,091, una mejora del 13 %. En el umbral de Youden, una probabilidad


Figura 6. *Curvas ROC sobre NHANES 2021-2023*

Nota. Predicciones fuera de muestra de la primera repetición de la validación cruzada. Las curvas del índice con contexto y de la regresión logística entrenada prácticamente se superponen.

de 0,11, la sensibilidad es 0,822 y la especificidad 0,656, con un valor predictivo negativo de 0,965 y uno positivo de 0,243. Por eso la herramienta sirve para descartar más que para confirmar. El umbral se eligió sobre las mismas predicciones que se evalúan, por lo que esas dos cifras son levemente optimistas.

Coefficientes. La Tabla 11 presenta los odds ratio del modelo de referencia ajustado a los 5.043 adultos, en ocho iteraciones de IRLS. Todos los coeficientes son significativos y, salvo el del sueño, que se discute en la nota, tienen el signo esperado. La edad domina, con un odds ratio de 4,06 por desvío estándar, seguida del IMC (1,46) y del PHQ-9 (1,39). El odds ratio por década, 2,27 [2,09; 2,47], es cercano a la regla de duplicación por década que usa el contexto del índice, aunque algo mayor: el intervalo no incluye el 2.

Recalibración del índice. Para saber si los coeficientes de la literatura están bien dimensionados, se entrenó una regresión logística cuyas variables son los siete componentes del índice, es decir, los cinco log-riesgos relativos de los factores y los dos del contexto. Si la literatura acertara la magnitud de un factor, su peso aprendido valdría 1. La Figura 8 muestra que los pesos de la frecuencia cardíaca, el sueño y el IMC son compatibles con 1, porque sus intervalos lo contienen; el sueño da exactamente 1,00. El estrés aproximado por PHQ-9 (5,32), la edad (1,28) y el sexo (1,58) pesan más de lo que asigna el índice, y el tabaquismo menos (0,70). Dos de esas diferencias son compatibles con el diseño transversal:

Figura 7. *Calibración por deciles de riesgo predicho*

Nota. Regresión logística con estilo de vida, edad y sexo; predicciones fuera de muestra agrupadas en diez deciles de alrededor de 504 personas.


Tabla 11. *Odds ratio de la regresión logística con estilo de vida, edad y sexo*

Variable	OR por 1 DE	IC 95 %	OR	IC 95 %	Unidad
Edad	4,06	3,51–4,69	2,27	2,09–2,47	+10 años
IMC	1,46	1,33–1,60	1,30	1,22–1,39	+5 kg/m ²
Sexo masculino	1,41	1,28–1,55	2,00	1,65–2,41	hombre/mujer
PHQ-9	1,39	1,27–1,52	1,43	1,30–1,57	+5 puntos
Fumador actual	1,24	1,14–1,35	1,85	1,44–2,37	sí/no
Sueño	1,14	1,04–1,24	1,09	1,03–1,15	+1 h
FC en reposo	1,11	1,01–1,21	1,08	1,01–1,17	+10 lpm

Nota. DE: desvío estándar de la variable en la muestra. Todos los coeficientes tienen $p < 0,05$; el de la frecuencia cardíaca es el menos significativo ($p = 0,035$). El odds ratio del sueño es positivo porque el sueño largo también se asocia con mayor riesgo y porque, en un diseño transversal, está confundido por la edad y la morbilidad previa.

quien ya tuvo un evento suele dejar de fumar y presenta más síntomas depresivos, lo que debilita el primer coeficiente y refuerza el segundo sin que eso diga algo sobre el riesgo futuro. En conjunto, reajustar los siete pesos lleva el AUC de 0,799 a 0,801: el orden que produce el índice ya es prácticamente el óptimo para estas variables, y no hay evidencia suficiente para reemplazar los coeficientes publicados por coeficientes estimados en un estudio transversal.

Figura 8. *Pesos aprendidos para cada componente del índice*



Nota. Peso de cada log-riesgo relativo del motor en una regresión logística ajustada a los 5.043 adultos, con su intervalo de confianza del 95 %. Un peso de 1 significa que la magnitud de la literatura coincide con la de los datos.

Trazabilidad del avance anterior. La versión previa de este documento reportaba, para una partición única de prueba del 30 %, un AUC de 0,605 con las variables de la aplicación y de 0,812 al agregar edad y sexo. Esa especificación se replicó con el código del proyecto sobre la misma muestra, que coincide exactamente (5.043 adultos y 597 casos). Las medias de validación cruzada, 0,603 y 0,803, son prácticamente iguales a las reportadas, 0,600 y 0,802. En la partición única se obtuvieron 0,615 y 0,795; la diferencia con lo reportado es compatible con la variabilidad de una sola partición, cuyo desvío entre particiones es del orden de 0,025 y 0,014 (Tabla 9). La heurística inicial da 0,5645 sobre la muestra completa, el mismo valor reportado (0,565). Por esa variabilidad, este documento reporta la validación cruzada repetida en lugar de una partición única.

8.4 Validación de la Implementación sobre UCI

Sobre el conjunto de Cleveland, la regresión logística con las 13 variables clínicas alcanza un AUC de 0,904 (Tabla 12) y supera a k vecinos (0,880). Con solo edad, sexo y frecuencia cardíaca máxima baja a 0,785, lo que cuantifica cuánto aportan el electrocardiograma y la prueba de esfuerzo. La reimplementación independiente en numpy reproduce los coeficientes y errores estándar de la implementación propia con una diferencia máxima de 2×10^{-14} en UCI y de 6×10^{-15} en NHANES, del orden del error de redondeo de la aritmética de doble precisión. En esta cohorte la edad no resulta significativa ($p = 0,38$) y el sexo masculino tiene un odds ratio de 6,0. Son rasgos de una cohorte de derivación cardiológica, no de la población general, y justifican que el estimador de la aplicación no se construya sobre estos datos.

Tabla 12. Validación cruzada sobre UCI Heart Disease (Cleveland)

Modelo	Variables	AUC	Brier
Prevalencia	ninguna	$0,500 \pm 0,000$	0,249
Regresión logística	edad, sexo, FC máxima (3)	$0,785 \pm 0,058$	0,190
Regresión logística	clínico básico (6)	$0,795 \pm 0,056$	0,185
Regresión logística	completo (13)	$0,904 \pm 0,032$	0,124
k vecinos ($k = 7$)	completo (13)	$0,880 \pm 0,042$	0,139

Nota. $n = 297$; validación cruzada estratificada 5×10 . El conjunto clínico básico agrega presión sistólica, colesterol y glucemia en ayunas.

8.5 Consecuencias para el Diseño

Los resultados se tradujeron en decisiones concretas sobre la aplicación:

- El puntaje heurístico inicial se reemplazó por el índice del motor, que discrimina mejor con diferencia significativa.
- Se mantienen los coeficientes de la literatura: entrenarlos sobre NHANES no mejora el orden y los introduciría con los sesgos de un diseño transversal.
- La aplicación incorpora un perfil opcional con edad, sexo, altura y tabaquismo, porque la edad y el sexo son los predictores más fuertes y el IMC y el tabaquismo aportan sobre ellos.
- La edad y el sexo se muestran como contexto y no dentro del puntaje: la combinación de ambos conserva la discriminación (0,799) sin que el puntaje castigue lo que la persona no puede modificar.

- El pronóstico se selecciona por serie y por usuario, porque ningún modelo gana en todas: en 8 de las 28 series el mejor fue un benchmark.

9. CONCLUSIONES

Las enfermedades cardiovasculares constituyen, simultáneamente, un desafío médico, tecnológico y social. La detección tardía del riesgo, las barreras de acceso a servicios preventivos y la baja alfabetización en salud configuran un escenario que demanda soluciones integrales. Desde la ingeniería de sistemas, este trabajo muestra que el aporte técnico de una plataforma preventiva no está en conectar un modelo de lenguaje, sino en construir y evaluar el sistema que produce las cifras.

El motor de predicción de Pulso resuelve ese problema con componentes implementados desde cero y medidos contra benchmarks. En pronóstico, el modelo seleccionado supera al pronóstico ingenuo en 23 de 28 series y recupera las pendientes y patrones semanales verdaderos. En detección, CUSUM identifica los cuatro cambios de régimen con 4,5 días de retraso medio. En estimación de riesgo, sobre 5.043 adultos reales, el índice construido con coeficientes publicados supera a la heurística inicial y rinde igual que una regresión logística entrenada con las mismas variables; con edad y sexo alcanza un AUC de 0,799, frente a 0,805 del mejor modelo entrenado, que además está calibrado.

El trabajo también responde con cifras una pregunta que la literatura de prototipos de salud digital suele dejar implícita: cuánto riesgo cardiovascular puede estimarse sin laboratorio. Los indicadores de estilo de vida, solos, discriminan de forma limitada (0,61); la edad y el sexo explican la mayor parte de la discriminación alcanzable (0,77); y las variables que la aplicación registra agregan una mejora pequeña pero significativa sobre ellas (+0,037). Reconocer y cuantificar esa restricción, en lugar de sortearla, delimita con honestidad el alcance del prototipo y orientó su rediseño.

Como trabajo de grado, el proyecto aporta a la salud digital y a la ingeniería de sistemas aplicada al sector salud, y se alinea con los Objetivos de Desarrollo Sostenible vinculados a salud y bienestar, reducción de desigualdades e innovación. Las siguientes fases abordarán la validación del pronóstico con series reales de dispositivos portátiles, la validación externa y la recalibración del estimador en población colombiana, un diseño longitudinal que permita predicción prospectiva, la incorporación de los ponderadores muestrales de NHANES y la validación con usuarios representativos y con la revisión de un profesional de la salud.

REFERENCIAS

- [1] Abramowitz, M., & Stegun, I. A. (Eds.). (1964). *Handbook of mathematical functions with formulas, graphs, and mathematical tables*. National Bureau of Standards.
- [2] Aune, D., Sen, A., ó'Hartaigh, B., Janszky, I., Romundstad, P. R., Tonstad, S., & Vatten, L. J. (2017). Resting heart rate and the risk of cardiovascular disease, total cancer, and all-cause mortality: A systematic review and dose-response meta-analysis of prospective studies. *Nutrition, Metabolism and Cardiovascular Diseases*, 27(6), 504–517. <https://doi.org/10.1016/j.numecd.2017.04.004>
- [3] Biduski, D., Bellei, E. A., Rodriguez, J. P. M., Zaina, L. A. M., & De Marchi, A. C. B. (2020). Assessing long-term user experience on a mobile health application through an in-app embedded conversation-based questionnaire. *Computers in Human Behavior*, 104, 106169. <https://doi.org/10.1016/j.chb.2019.106169>
- [4] Cappuccio, F. P., Cooper, D., D'Elia, L., Strazzullo, P., & Miller, M. A. (2011). Sleep duration predicts cardiovascular outcomes: A systematic review and meta-analysis of prospective studies. *European Heart Journal*, 32(12), 1484–1492. <https://doi.org/10.1093/eurheartj/ehr007>
- [5] Centers for Disease Control and Prevention, National Center for Health Statistics. (2024). *National Health and Nutrition Examination Survey: August 2021 – August 2023 data files* [Conjunto de datos]. U.S. Department of Health and Human Services. <https://wwwn.cdc.gov/nchs/nhanes/continuousnhanes/default.aspx?Cycle=2021-2023>
- [6] Cover, T., & Hart, P. (1967). Nearest neighbor pattern classification. *IEEE Transactions on Information Theory*, 13(1), 21–27. <https://doi.org/10.1109/TIT.1967.1053964>
- [7] Dawber, T. R., Meadors, G. F., & Moore, F. E. (1951). Epidemiological approaches to heart disease: The Framingham Study. *American Journal of Public Health*, 41(3), 279–281. <https://doi.org/10.2105/AJPH.41.3.279>
- [8] Detrano, R., Janosi, A., Steinbrunn, W., Pfisterer, M., Schmid, J., Sandhu, S., Guppy, K., Lee, S., & Froelicher, V. (1989). International application of a new probability algorithm for the diagnosis of coronary artery disease. *American Journal of Cardiology*, 64(5), 304–310. [https://doi.org/10.1016/0002-9149\(89\)90524-9](https://doi.org/10.1016/0002-9149(89)90524-9)
- [9] Efron, B., & Tibshirani, R. J. (1993). *An introduction to the bootstrap*. Chapman & Hall.

- [10] Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. *The Annals of Statistics*, 29(5), 1189–1232. <https://doi.org/10.1214/aos/1013203451>
- [11] Gardner, E. S., Jr., & McKenzie, E. (1985). Forecasting trends in time series. *Management Science*, 31(10), 1237–1246. <https://doi.org/10.1287/mnsc.31.10.1237>
- [12] Global BMI Mortality Collaboration. (2016). Body-mass index and all-cause mortality: Individual-participant-data meta-analysis of 239 prospective studies in four continents. *The Lancet*, 388(10046), 776–786. [https://doi.org/10.1016/S0140-6736\(16\)30175-1](https://doi.org/10.1016/S0140-6736(16)30175-1)
- [13] Hanley, J. A., & McNeil, B. J. (1982). The meaning and use of the area under a receiver operating characteristic (ROC) curve. *Radiology*, 143(1), 29–36. <https://doi.org/10.1148/radiology.143.1.7063747>
- [14] Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The elements of statistical learning: Data mining, inference, and prediction* (2.^a ed.). Springer. <https://doi.org/10.1007/978-0-387-84858-7>
- [15] Hawkins, D. M. (1987). Self-starting CUSUM charts for location and scale. *Journal of the Royal Statistical Society: Series D (The Statistician)*, 36(4), 299–316.
- [16] Hawkins, D. M., & Olwell, D. H. (1998). *Cumulative sum charts and charting for quality improvement*. Springer. <https://doi.org/10.1007/978-1-4612-1686-5>
- [17] Holt, C. C. (2004). Forecasting seasonals and trends by exponentially weighted moving averages. *International Journal of Forecasting*, 20(1), 5–10. <https://doi.org/10.1016/j.ijforecast.2003.09.015> (Trabajo original publicado en 1957)
- [18] Hyndman, R. J., & Athanasopoulos, G. (2021). *Forecasting: Principles and practice* (3.^a ed.). OTexts. <https://otexts.com/fpp3/>
- [19] Hyndman, R. J., & Koehler, A. B. (2006). Another look at measures of forecast accuracy. *International Journal of Forecasting*, 22(4), 679–688. <https://doi.org/10.1016/j.ijforecast.2006.03.001>
- [20] Janosi, A., Steinbrunn, W., Pfisterer, M., & Detrano, R. (1988). *Heart Disease* [Conjunto de datos]. UCI Machine Learning Repository. <https://doi.org/10.24432/C52P4X>
- [21] Krittanawong, C., Virk, H. U. H., Bangalore, S., Wang, Z., Johnson, K. W., Pinotti, R., Zhang, H., Kaplin, S., Narasimhan, B., Kitai, T., Baber, U., Halperin, J. L., & Tang, W.

- H. W. (2020). Machine learning prediction in cardiovascular diseases: A meta-analysis. *Scientific Reports*, 10(1), 16057. <https://doi.org/10.1038/s41598-020-72685-1>
- [22] Kroenke, K., Spitzer, R. L., & Williams, J. B. W. (2001). The PHQ-9: Validity of a brief depression severity measure. *Journal of General Internal Medicine*, 16(9), 606–613. <https://doi.org/10.1046/j.1525-1497.2001.016009606.x>
- [23] le Cessie, S., & van Houwelingen, J. C. (1992). Ridge estimators in logistic regression. *Journal of the Royal Statistical Society: Series C (Applied Statistics)*, 41(1), 191–201. <https://doi.org/10.2307/2347628>
- [24] Liao, P., Greenewald, K., Klasnja, P., & Murphy, S. (2020). Personalized HeartSteps: A reinforcement learning algorithm for optimizing physical activity. *Proceedings of the ACM on Interactive, Mobile, Wearable and Ubiquitous Technologies*, 4(1), 1–22. <https://doi.org/10.1145/3381007>
- [25] Ministerio de Salud y Protección Social de Colombia. (2022). *Análisis de Situación de Salud (ASIS) Colombia*. Bogotá D.C. <https://www.minsalud.gov.co>
- [26] Montgomery, D. C. (2019). *Introduction to statistical quality control* (8.^a ed.). Wiley.
- [27] National Heart, Lung, and Blood Institute. (2026). *Framingham Heart Study: Three generations of dedication* [Sitio web]. Recuperado el 15 de agosto de 2026, de <https://www.framinghamheartstudy.org>
- [28] Observatorio Nacional de Salud. (2021). *Informe sobre enfermedades cardiovasculares en Colombia*. Instituto Nacional de Salud. <https://www.ins.gov.co>
- [29] Organización Mundial de la Salud. (2026a). *Cardiovascular diseases (CVDs): Key facts*. OMS. <https://www.who.int/news-room/fact-sheets/detail/cardiovascular-diseases-cvds>
- [30] Organización Mundial de la Salud. (2026b). *Global Health Observatory* [Repositorio de datos]. Recuperado el 15 de agosto de 2026, de <https://www.who.int/data/gho>
- [31] Page, E. S. (1954). Continuous inspection schemes. *Biometrika*, 41(1–2), 100–115. <https://doi.org/10.1093/biomet/41.1-2.100>
- [32] Pinzón, A., Aristizábal, J. C., Cubillos-Garzón, L. A., González, C., & Lara-Díaz, M. F. (2020). Factores de riesgo cardiovascular en población adulta colombiana: brechas en tamizaje y prevención. *Revista Colombiana de Cardiología*, 27(4), 263–272.

- [33] Richardson, S., Shaffer, J. A., Falzon, L., Krupka, D., Davidson, K. W., & Edmondson, D. (2012). Meta-analysis of perceived stress and its association with incident coronary heart disease. *American Journal of Cardiology*, 110(12), 1711–1716. <https://doi.org/10.1016/j.amjcard.2012.08.004>
- [34] Roberts, S. W. (1959). Control chart tests based on geometric moving averages. *Technometrics*, 1(3), 239–250. <https://doi.org/10.1080/00401706.1959.10489860>
- [35] Sen, P. K. (1968). Estimates of the regression coefficient based on Kendall's tau. *Journal of the American Statistical Association*, 63(324), 1379–1389. <https://doi.org/10.1080/01621459.1968.10480934>
- [36] Theil, H. (1950). A rank-invariant method of linear and polynomial regression analysis, I. *Proceedings of the Royal Netherlands Academy of Sciences*, 53, 386–392.
- [37] Van Calster, B., McLernon, D. J., van Smeden, M., Wynants, L., & Steyerberg, E. W. (2019). Calibration: The Achilles heel of predictive analytics. *BMC Medicine*, 17, 230. <https://doi.org/10.1186/s12916-019-1466-7>
- [38] Welford, B. P. (1962). Note on a method for calculating corrected sums of squares and products. *Technometrics*, 4(3), 419–420. <https://doi.org/10.1080/00401706.1962.10490022>
- [39] Weng, S. F., Reps, J., Kai, J., Garibaldi, J. M., & Qureshi, N. (2017). Can machine-learning improve cardiovascular risk prediction using routine clinical data? *PLoS ONE*, 12(4), e0174944. <https://doi.org/10.1371/journal.pone.0174944>
- [40] Winters, P. R. (1960). Forecasting sales by exponentially weighted moving averages. *Management Science*, 6(3), 324–342. <https://doi.org/10.1287/mnsc.6.3.324>
- [41] Yin, J., Jin, X., Shan, Z., Li, S., Huang, H., Li, P., Peng, X., Peng, Z., Yu, K., Bao, W., Yang, W., Chen, X., & Liu, L. (2017). Relationship of sleep duration with all-cause mortality and cardiovascular events: A systematic review and dose-response meta-analysis of prospective cohort studies. *Journal of the American Heart Association*, 6(9), e005947. <https://doi.org/10.1161/JAHA.117.005947>
- [42] Youden, W. J. (1950). Index for rating diagnostic tests. *Cancer*, 3(1), 32–35.
- [43] Yusuf, S., Hawken, S., Ôunpuu, S., Dans, T., Avezum, A., Lanas, F., McQueen, M., Budaj, A., Pais, P., Varigos, J., & Lisheng, L. (2004). Effect of potentially modifiable

- risk factors associated with myocardial infarction in 52 countries (the INTERHEART study): Case-control study. *The Lancet*, 364(9438), 937–952. [https://doi.org/10.1016/S0140-6736\(04\)17018-9](https://doi.org/10.1016/S0140-6736(04)17018-9)
- [44] Zeevi, D., Korem, T., Zmora, N., Israeli, D., Rothschild, D., Weinberger, A., Ben-Yacov, O., Lador, D., Avnit-Sagi, T., Lotan-Pompan, M., Suez, J., Mahdi, J. A., Matot, E., Malka, G., Kosower, N., Rein, M., Zilberman-Schapira, G., Dohnalová, L., Pevsner-Fischer, M., . . . Segal, E. (2015). Personalized nutrition by prediction of glycemic responses. *Cell*, 163(5), 1079–1094. <https://doi.org/10.1016/j.cell.2015.11.001>
- [45] Zhang, D., Shen, X., & Qi, X. (2016). Resting heart rate and all-cause and cardiovascular mortality in the general population: A meta-analysis. *Canadian Medical Association Journal*, 188(3), E53–E63. <https://doi.org/10.1503/cmaj.150535>

ANEXO A. REPRODUCIBILIDAD

Todas las cifras de este documento se generan con scripts del repositorio del proyecto, con semillas fijas y sin dependencias de aprendizaje automático externas. La Tabla 13 lista los comandos y los archivos que producen, y la Tabla 14, la huella SHA-256 de los archivos de NHANES de los que parte la muestra, para que cualquier persona pueda comprobar que trabaja con los mismos datos. La corrida completa de NHANES tarda alrededor de un minuto en un computador portátil.

Tabla 13. *Comandos de reproducción y resultados que generan*

Comando	Resultado
<code>npm run test:ml</code>	Compila el motor y ejecuta las 70 pruebas automatizadas.
<code>npm run evaluar</code>	Evaluación sobre la cohorte sintética (Tablas 7 y 8): <code>docs/evaluacion-sintetica.txt</code> y <code>.json</code> .
<code>npm run nhanes:descargar</code>	Descarga los siete archivos XPORT del CDC.
<code>npm run nhanes:muestra</code>	Construye la muestra analítica (Tabla 4): <code>data/nhanes-2021-2023/muestra-analitica.csv</code> .
<code>npm run entrenar:nhanes</code>	Validación cruzada, bootstrap, calibración, coeficientes y réplica del avance anterior (Tablas 6, 9, 10 y 11): <code>docs/entrenamiento-nhanes.txt</code> y <code>.json</code> .
<code>npm run entrenar</code>	Experimento sobre UCI (Tabla 12): <code>docs/entrenamiento-uci.txt</code> y <code>.json</code> .
<code>python3 scripts/verificar-logistica.py</code>	Reimplementación independiente en numpy; recibe el JSON de UCI o de NHANES.
<code>npm run figuras</code>	Figuras del documento en <code>docs/figuras/</code> .

Tabla 14. *Archivos de NHANES 2021-2023 utilizados*

Archivo	Filas	SHA-256
DEMO_L	11.933	ca4374a158b493b8b0163e1388da21d57a18d1b9cecff2aa4e2fa2bec494fe23
BPXO_L	7.801	189aa9bed689d2c69cf8d780b01de85073276fea5694dd52cdf696229f9054a6
BMX_L	8.860	44440c416d9ad709e8b1708a5975378ab4d5b18edc39eb5015c2ae7186500170
SLQ_L	8.501	918c3258b2f466ac1cae55ea45330c736dbdc573ee4dc72306e3d2b222764741
DPQ_L	6.337	25605a02685035fe997477b31a0991cca2776b0f72f24a8e61ac5b018456304b
MCQ_L	11.744	0889bb3eaa5adedf1a11c4af2d4776fc4c4c3cfdeea24fcedb77c4636b478f61
SMQ_L	9.015	abbefebfa5585b1e19c079fa14be20c113a4649318070197214b258d05b93c50