

Plataforma PWA con IA para la Prevención Cardiovascular: Predicción de Riesgo, Alimentación, Ejercicio y Seguimiento Personalizado

Agustín Peralta Guarín
Natalia Moncaleano Montero
Facultad de Ingeniería, Ingeniería de Sistemas
Universidad de San Buenaventura
Bogotá, Colombia

Resumen—Las enfermedades del sistema circulatorio constituyen la primera causa de mortalidad general en Colombia, con tasas ajustadas superiores a 130 muertes por cada 100.000 habitantes. Más de tres cuartas partes de esa carga se asocia a factores de riesgo modificables, de modo que existe una ventana de intervención preventiva que hoy no se aprovecha, principalmente porque el tamizaje cardiovascular depende de que la persona asista a consulta. Este proyecto desarrolla Pulso, una Aplicación Web Progresiva (PWA) con inteligencia artificial dirigida a personas adultas de 40 a 69 años residentes en Colombia, sin diagnóstico previo de enfermedad cardiovascular. Pulso estima el riesgo cardiovascular de la persona y, a partir de ese resultado, propone recomendaciones de alimentación con ingredientes, cantidades y preparaciones propias de cada región, planes de vida saludable, rutinas de ejercicio y reportes periódicos de seguimiento. Para estimar el riesgo se entrenó una regresión logística con 5.043 adultos de la encuesta NHANES 2021-2023, elegida después de compararla con gradient boosting y k vecinos más cercanos en una validación cruzada estratificada 5×10 . Con las variables de estilo de vida, la edad y el sexo alcanza un área bajo la curva ROC de 0,805 con pendiente de calibración de 0,99, y la contribución de cada variable a cada predicción se calcula de forma exacta, dado que en un modelo lineal el valor SHAP tiene forma cerrada. La inferencia se ejecuta en el servidor. Sin conexión, la aplicación conserva la última evaluación con su explicación, el plan alimentario, las rutinas y el histórico, mientras que una evaluación nueva se calcula al recuperar la conectividad. Para validar el prototipo se medirán la discriminación y la calibración del modelo, se harán pruebas de usabilidad con la escala SUS en varios dispositivos y con distintas condiciones de red, y un profesional de salud revisará las recomendaciones.

Palabras clave—enfermedades cardiovasculares, aprendizaje automático, regresión logística, aplicación web progresiva, prevención primaria, salud digital

Abstract—Circulatory system diseases are the leading cause of overall mortality in Colombia, with age-adjusted rates above 130 deaths per 100,000 inhabitants. More than three quarters of that burden is associated with modifiable risk factors, which leaves a window for preventive intervention that is currently missed, mainly because cardiovascular screening depends on the person attending a medical appointment. This project develops Pulso, an artificial intelligence Progressive Web Application (PWA) aimed at adults aged 40 to 69 living in Colombia with no prior

diagnosis of cardiovascular disease. Pulso estimates the person's cardiovascular risk and, based on that result, proposes dietary recommendations with ingredients, quantities and preparations typical of each region, healthy lifestyle plans, exercise routines and periodic follow-up reports. Risk is estimated with a logistic regression trained on 5,043 adults from the NHANES 2021-2023 survey, chosen after comparing it with gradient boosting and k-nearest neighbours in a 5×10 stratified cross-validation. With lifestyle variables, age and sex it reaches an area under the ROC curve of 0.805 with a calibration slope of 0.99, and the contribution of each variable to each prediction is computed exactly, since SHAP values have a closed form for linear models. Inference runs on the server. Offline, the application keeps the latest evaluation with its explanation, the meal plan, the routines and the history, while a new evaluation is computed once connectivity is restored. To validate the prototype, the model's discrimination and calibration will be measured, usability will be tested with the SUS scale on several devices and network conditions, and a health professional will review the recommendations.

Keywords—cardiovascular diseases, machine learning, logistic regression, progressive web application, primary prevention, digital health

I. INTRODUCCIÓN

Las enfermedades cardiovasculares (ECV) constituyen la primera causa de mortalidad en Colombia. Las enfermedades del sistema circulatorio encabezan de forma sostenida las estadísticas nacionales de mortalidad general, con tasas ajustadas superiores a 130 muertes por cada 100.000 habitantes según los reportes del Ministerio de Salud y Protección Social [1]. Este comportamiento reproduce, a escala nacional, un fenómeno global: la Organización Mundial de la Salud estima cerca de 19,8 millones de muertes anuales por esta causa, alrededor del 32 % de las defunciones registradas en el mundo [2], mientras que el World Heart Report 2023 de la World Heart Federation calcula 20,5 millones de muertes para el año 2021 [3].

Ahora bien, la magnitud del problema no es su rasgo más determinante. Más de tres cuartas partes de la carga atribuible a estas enfermedades se asocia a factores de riesgo modificables, tales como el sedentarismo, la alimentación inadecuada, el tabaquismo, la obesidad y el estrés. Existe, por consiguiente, una ventana de intervención amplia que en el contexto colombiano no se aprovecha.

El problema está en cuándo se detecta el riesgo. En el país, el tamizaje cardiovascular ocurre casi siempre dentro de una consulta: la persona tiene que asistir y el profesional tiene que aplicar una escala de riesgo durante la atención. Por eso muchos adultos no conocen su nivel de riesgo hasta que sufren un infarto de miocardio o un accidente cerebrovascular, y para entonces ya no se trata de prevenir. La desigualdad territorial lo empeora, porque en los municipios rurales y dispersos hay menos servicios preventivos y la conexión a internet es intermitente.

Desde la ingeniería de sistemas es posible abordar esta situación mediante el desarrollo de aplicaciones web progresivas inteligentes que analicen datos clínicos y de estilo de vida del usuario, calculen su nivel de riesgo cardiovascular y generen planes de acción personalizados. La elección de la arquitectura de Aplicación Web Progresiva (PWA) responde a la necesidad de ofrecer una experiencia equivalente a la de una aplicación nativa en cualquier dispositivo con navegador web, sin depender de tiendas de aplicaciones, con capacidad de funcionamiento sin conexión y envío de notificaciones push para alertas de salud críticas.

Las tecnologías emergentes como la inteligencia artificial y el aprendizaje automático han demostrado un alto potencial para mejorar la precisión en la estratificación del riesgo cardiovascular y la personalización de intervenciones preventivas [4], [5]. Pulso aplica estas técnicas en una PWA pensada para adultos de 40 a 69 años que viven en Colombia, no tienen diagnóstico de enfermedad cardiovascular y cuentan con un dispositivo con navegador web. Además de estimar el riesgo, la aplicación entrega recomendaciones de alimentación con ingredientes concretos, planes de vida saludable y rutinas de ejercicio ajustadas a cada usuario.

Este documento analiza las limitaciones existentes y propone un enfoque viable para el diseño de una PWA inteligente orientada a la prevención cardiovascular integral en el contexto colombiano, mediante datos y recomendaciones contextualizadas por región, cultura alimentaria y disponibilidad de ingredientes locales.

II. PLANTEAMIENTO DEL PROBLEMA

En Colombia las enfermedades cardiovasculares son la primera causa de muerte, y no porque falte conocimiento clínico para prevenirlas: la falla está en el momento en que se detecta el riesgo. Más del 75 % de la carga de estas enfermedades se asocia a factores de riesgo modificables, así que hay un margen amplio para intervenir que hoy se desaprovecha.

El tamizaje disponible es reactivo. Solo ocurre si la persona va a consulta y si el profesional aplica una escala de riesgo durante la atención, de modo que quien no consulta queda sin

evaluar. El resultado es que una parte importante de los adultos se enteran de su riesgo cuando ya tuvo un evento agudo, y en ese punto la prevención llega tarde.

La brecha tampoco es igual en todo el territorio. En los municipios rurales y dispersos hay menos servicios preventivos, la conexión es intermitente y los teléfonos suelen ser de gama baja, de manera que la falta de detección pesa más en esas zonas.

A esta condición se suma una limitación tecnológica. Las herramientas digitales existentes fueron diseñadas para entornos hospitalarios, requieren conexión permanente, entregan un porcentaje de riesgo sin plan de acción asociado y distribuyen en aplicaciones independientes lo que el usuario necesita de forma integrada. Por consiguiente, quedan excluidas precisamente las poblaciones con mayor barrera de acceso y mayor carga de enfermedad.

El presente trabajo delimita su población objetivo en personas adultas entre 40 y 69 años residentes en Colombia, sin diagnóstico previo de enfermedad cardiovascular y con acceso a un dispositivo con navegador web. El rango etario no es arbitrario: corresponde al intervalo en el que están validadas las escalas de riesgo cardiovascular a diez años de referencia, como SCORE2, desarrollada específicamente para personas aparentemente sanas de 40 a 69 años [6]. Por debajo de los 40 años la estimación a diez años tiende a subestimar el riesgo de por vida, y por encima de los 69 el manejo corresponde al ámbito clínico y no al autotamizaje.

La situación problema se manifiesta en cuatro dimensiones observables. En primer lugar, el diagnóstico tardío, dado que el tamizaje se concentra en el nivel asistencial y la primera señal de alerta termina siendo el evento agudo. En segundo lugar, la fragmentación de la orientación preventiva, puesto que las calculadoras de riesgo entregan un porcentaje sin plan de acción asociado, las aplicaciones de nutrición no consideran el perfil de riesgo cardiovascular y las de ejercicio no incorporan alertas de seguridad según el nivel de riesgo. En tercer lugar, la barrera de acceso tecnológico: las plataformas actuales hay que descargarlas de una tienda de aplicaciones, ocupan espacio en el teléfono y dejan de funcionar sin conexión. En cuarto lugar, las recomendaciones están descontextualizadas. Las guías nutricionales de referencia parten de los patrones de alimentación de países de altos ingresos, y es poco probable que alguien siga una recomendación que no tiene en cuenta qué ingredientes consigue en su región, cuánto cuestan ni qué se acostumbra comer en Colombia.

El interrogante que orienta esta investigación es:

¿De qué manera una Aplicación Web Progresiva impulsada por inteligencia artificial puede contribuir a la predicción, prevención y reducción del riesgo cardiovascular en personas adultas entre 40 y 69 años en Colombia, mediante recomendaciones personalizadas y contextualizadas de alimentación, ejercicio y hábitos de vida saludable?

II-A. Antecedentes

Los antecedentes que sustentan este proyecto se organizan en cuatro campos que han evolucionado de manera indepen-

diente: la predicción del riesgo cardiovascular mediante aprendizaje automático, la nutrición computacional, la prescripción asistida de actividad física y la arquitectura de aplicaciones web progresivas aplicada a la salud.

En cuanto a la predicción del riesgo, Weng et al. [5] compararon cuatro algoritmos con los registros clínicos rutinarios de 378.256 pacientes de atención primaria del Reino Unido. Los cuatro superaron al algoritmo de referencia del American College of Cardiology, y el de redes neuronales identificó correctamente un 7,6% más de pacientes. Lo valioso del resultado es que la mejora no vino de datos especializados o difíciles de conseguir, sino de aprovechar mejor variables clínicas que ya estaban disponibles. Debe advertirse, no obstante, que el estudio se realizó sobre población británica, por lo cual la transferencia de sus resultados al contexto colombiano requiere validación posterior. En la misma línea, Krittanawong et al. [4] realizaron un metaanálisis sobre la predicción de eventos cardiovasculares con técnicas de aprendizaje automático y reportaron desempeños comparables o superiores a los de las escalas clínicas tradicionales, señalando al mismo tiempo la heterogeneidad metodológica y la escasa validación externa como limitaciones persistentes del campo. Esa falta de validación externa es una de las razones por las que el modelo propuesto explica cada predicción que entrega.

En nutrición computacional, Zeevi et al. [7] encontraron que la respuesta glucémica a un mismo alimento cambia bastante de una persona a otra, y que un modelo predictivo alimentado con datos personales permite diseñar dietas con resultados clínicos medibles. De ahí se desprende que una recomendación nutricional genérica tiene un límite de efectividad, y que personalizarla es necesario para obtener resultados.

Respecto de la prescripción de actividad física asistida por sistemas de recomendación, diversos trabajos han explorado la generación automática de planes adaptados al perfil del usuario; Liao et al. [8] mostraron que un algoritmo que personaliza las sugerencias de actividad a partir de los datos de cada persona puede optimizar la actividad física diaria frente a sugerencias no personalizadas. Para el caso cardiovascular, la literatura enfatiza la necesidad de incorporar límites de seguridad y progresividad controlada, dado que una prescripción inadecuada en población de alto riesgo puede resultar contraproducente.

Sobre las aplicaciones de salud, Biduski et al. [9] siguieron durante un periodo largo la experiencia de uso de una aplicación móvil y vieron que la satisfacción se concentra en las primeras semanas y después cae de forma sostenida. Por eso el seguimiento activo y las notificaciones importan para que el usuario no abandone. En cuanto a la arquitectura, la literatura señala ventajas de las PWA sobre las aplicaciones nativas en salud pública: no dependen de tiendas de aplicaciones, ocupan menos almacenamiento, se actualizan sin que el usuario intervenga y siguen funcionando con conectividad intermitente gracias a los Service Workers.

En el contexto nacional, los reportes del Ministerio de Salud y Protección Social [1] ubican las enfermedades del sistema circulatorio como primera causa de mortalidad general, y la

literatura ha identificado barreras estructurales que incluyen la baja cobertura de tamizaje en población general, las desigualdades entre las ciudades capitales y los municipios rurales en el acceso a servicios preventivos y la limitada adopción tecnológica en atención primaria. En la revisión realizada no apareció ninguna herramienta digital de autotamizaje cardiovascular para adultos colombianos que funcione sin conexión y ajuste las recomendaciones de alimentación a los ingredientes de cada región.

Vistos en conjunto, los antecedentes muestran que cada pieza ya existe por separado y está madura: modelos predictivos validados en cohortes grandes, nutrición personalizada con evidencia clínica, sistemas que recomiendan actividad física y PWA probadas en salud pública. Sin embargo, no se identificó una plataforma que articule estos componentes en un solo flujo de uso, de acceso libre, funcional sin conexión y con recomendaciones contextualizadas por región y cultura alimentaria. Ese es el vacío que aborda el presente proyecto.

III. JUSTIFICACIÓN

III-A. Relevancia social

Las enfermedades cardiovasculares no representan únicamente un problema de salud pública, sino también un indicador de desigualdad social. En Colombia muchos adultos no tienen acceso oportuno a servicios preventivos, y eso se traduce en más muertes por eventos que se podían evitar. Pulso es de acceso libre: cualquier persona con un navegador puede evaluar su riesgo cardiovascular y recibir orientación nutricional con ingredientes concretos y recomendaciones de vida saludable, lo que ayuda a acortar la distancia en detección entre las ciudades capitales y el resto del país.

La arquitectura PWA encaja con las condiciones del país, donde la conexión a internet varía mucho entre regiones y la mayoría de las personas se conecta desde teléfonos de gama media o baja. Como la aplicación funciona sin conexión, un usuario de un municipio rural puede consultar su último nivel de riesgo, sus recomendaciones de alimentación y sus rutinas aunque en ese momento no tenga señal.

III-B. Relevancia teórica

La investigación se apoya en estudios que demuestran la efectividad de la inteligencia artificial en la estratificación del riesgo cardiovascular y en la personalización de intervenciones preventivas [4], [5]. Desde la ingeniería de sistemas, este trabajo fortalece la base teórica sobre el uso de tecnologías web progresivas inteligentes integradas con sistemas de información en salud, y aporta al campo de la salud digital, la nutrición computacional y la medicina preventiva de precisión.

III-C. Relevancia práctica

Con la aplicación, una persona de 40 a 69 años que vive en Colombia podrá registrar sus datos clínicos y de estilo de vida y obtener a cambio una estimación de su riesgo cardiovascular, calculada con una regresión logística entrenada sobre una encuesta poblacional, junto con lo que aporta cada variable

a ese resultado. Recibirá además recomendaciones de alimentación con ingredientes, cantidades, formas de preparación y alternativas según su región y sus costumbres; planes de vida saludable sobre estrés, sueño, hidratación y descanso; rutinas de ejercicio acordes con su condición física, su nivel de riesgo y sus objetivos; recordatorios preventivos por notificaciones push, y reportes periódicos, consultables sin conexión, para ver cómo evolucionan sus indicadores.

III-D. Relevancia disciplinar

El proyecto reúne varias áreas de la ingeniería de sistemas (arquitectura de software, ciencia de datos, desarrollo web y diseño de experiencia de usuario) y las aplica a un problema de salud pública con datos epidemiológicos verificables. Tener que funcionar sin conexión y en teléfonos de gama baja obliga a decidir con cuidado qué se guarda en el dispositivo, cómo se sincroniza y dónde se ejecuta el modelo. Las soluciones que se adopten pueden servir a otros proyectos de salud digital con las mismas restricciones.

IV. ALCANCE Y LIMITACIONES

El presente proyecto tiene como alcance el desarrollo de Pulso, una Aplicación Web Progresiva basada en inteligencia artificial y aprendizaje automático, orientada a la estimación del riesgo cardiovascular, la generación de recomendaciones alimenticias con ingredientes específicos, planes de vida saludable, rutinas de ejercicio personalizadas y el seguimiento continuo del estado de salud cardiovascular del usuario. El sistema será instalable en dispositivos móviles, tabletas y equipos de escritorio, mantendrá disponibles sin conexión las funciones de consulta mediante Service Workers y enviará notificaciones push para alertas preventivas.

IV-A. Población objetivo

La población objetivo del proyecto son las personas adultas entre 40 y 69 años residentes en Colombia, sin diagnóstico previo de enfermedad cardiovascular y con acceso a un dispositivo con navegador web. Cada uno de estos criterios tiene su razón:

- El rango de 40 a 69 años es el mismo en el que están validadas las escalas de riesgo cardiovascular a diez años que el modelo toma como referencia. En menores de 40 la estimación a diez años suele subestimar el riesgo acumulado a lo largo de la vida, y a partir de los 70 el manejo corresponde a la atención clínica especializada.
- Al exigir que no haya diagnóstico previo, el proyecto se limita a la prevención primaria. Quien ya tuvo un evento cardiovascular necesita seguimiento médico, no autotamizaje, y por eso queda por fuera.
- Vivir en Colombia es lo que permite ajustar las recomendaciones de alimentación a los ingredientes de cada región y a la cultura alimentaria del país, y lo que sitúa el sistema bajo la norma nacional de protección de datos personales.
- Sin un dispositivo con navegador web no es posible usar el sistema. Las personas que no cuentan con ese

acceso no pueden ser atendidas por esta solución, y ello constituye una limitación estructural reconocida del proyecto.

IV-B. Módulos comprendidos en el alcance

- Ingreso de datos clínicos y de estilo de vida con almacenamiento local mediante IndexedDB.
- Estimación del riesgo cardiovascular mediante una regresión logística entrenada sobre la encuesta NHANES 2021-2023 [10], seleccionada frente a gradient boosting y k vecinos más cercanos, con explicación de cada predicción mediante valores SHAP calculados de forma exacta. El conjunto UCI Heart Disease sirve para comprobar que los algoritmos están bien implementados; el Framingham Heart Study y el WHO Global Health Observatory se citan como respaldo de los factores de riesgo, pero no se usan para entrenar.
- Recomendaciones de alimentación personalizadas: ingredientes, cantidades, forma de preparación, alternativas según la región y un plan semanal con su lista de mercado.
- Recomendaciones de vida saludable sobre estrés, sueño, hidratación y hábitos diarios.
- Rutinas de ejercicio adaptadas al nivel de riesgo, con progresividad automática y alertas de seguridad.
- Sistema de seguimiento con tablero interactivo, alertas preventivas y reportes periódicos exportables en PDF.

IV-C. Vigencia y naturaleza temporal de los datos

El proyecto trabaja con dos tipos de datos que tienen vigencias distintas y no deben confundirse. Los datos epidemiológicos que sustentan el planteamiento del problema corresponden al periodo 2021-2023. La cifra de 20,5 millones de muertes por enfermedad cardiovascular refleja el año 2021 y fue publicada en el World Heart Report 2023 de la World Heart Federation [3]. Se trata, por tanto, de la evidencia disponible más reciente sobre la magnitud del problema.

El conjunto de entrenamiento del modelo es la encuesta NHANES del ciclo agosto de 2021 a agosto de 2023, publicada en 2024 [10], que coincide en periodo con la evidencia epidemiológica. El UCI Heart Disease [11], recolectado en 1988, solo se usa para comprobar que los algoritmos implementados reproducen resultados ya publicados. El Framingham Heart Study no se usa para entrenar, porque acceder a sus datos individuales requiere la aprobación de un comité de ética y un acuerdo de uso, y el WHO Global Health Observatory solo publica cifras agregadas por país; los dos se citan como respaldo de los factores de riesgo [12]. Esto tiene dos consecuencias. La primera es que el resultado debe leerse como un nivel de riesgo basado en patrones de población, no como una medida del estado clínico actual del usuario. La segunda es que el modelo aprende de población estadounidense, por lo que volver a validarlo con datos colombianos queda como trabajo futuro.

IV-D. *El sistema no opera en tiempo real*

Pulso evalúa el riesgo de forma periódica y no monitorea al usuario de forma continua. Es una decisión tomada a propósito, por cuatro razones. La primera es que los datos vienen del autorreporte: el usuario los ingresa a mano, así que la frecuencia de actualización depende de él. La segunda es que el sistema no se conecta con relojes inteligentes, sensores biométricos ni historias clínicas electrónicas, porque esa integración exige estándares de intercambio clínico y acuerdos con instituciones que están fuera del alcance de un prototipo académico. La tercera es que, para funcionar sin conexión, los datos se guardan en el navegador con IndexedDB y se sincronizan cuando vuelve la red. La cuarta es que un sistema de monitoreo continuo con alertas clínicas inmediatas se acercaría a la categoría de dispositivo médico, con una regulación que este proyecto no aborda.

Por lo anterior, el nivel de riesgo que muestra la aplicación corresponde siempre al último registro ingresado por el usuario, y las alertas push cumplen una función de recordatorio y de estímulo a la reevaluación periódica, no de detección de eventos agudos. Ante una urgencia cardiovascular, la aplicación no sirve como medio de vigilancia ni reemplaza la atención de urgencias.

IV-E. *Limitaciones*

Por razones éticas y de confidencialidad no es posible acceder a bases de datos clínicas reales de pacientes, así que los modelos se entrenan con conjuntos de datos públicos y anonimizados. El desarrollo llega hasta un prototipo funcional en fase experimental, que no se implementará en instituciones médicas, y su validación se basa en métricas de desempeño computacional y en pruebas de usabilidad con usuarios representativos.

Una limitación de especial importancia se deriva de la delimitación nacional del proyecto. El conjunto de entrenamiento proviene de población estadounidense y no colombiana, y aplicar a un contexto nacional un modelo aprendido sobre una población con perfiles demográficos, dietarios y de acceso a servicios de salud distintos puede introducir un sesgo sistemático en la estimación del riesgo. A ello se suman tres límites propios de la encuesta que se declaran de forma explícita: su diseño es transversal, de modo que permite estimar la asociación con el antecedente de un evento cardiovascular pero no la incidencia futura; el desenlace es autorreportado; y el estrés se aproxima con el cuestionario PHQ-9 [13], que mide síntomas depresivos y no estrés percibido. La explicación por variable y el aviso de que el resultado es orientativo reducen estos problemas, pero no los resuelven: antes de cualquier uso fuera del prototipo académico habría que validar el modelo con datos de población colombiana.

Hay otras limitaciones. Las recomendaciones son orientativas y no reemplazan el criterio de un médico. Los ingredientes disponibles cambian de una región a otra. Lo que funciona sin conexión depende de cuánto soporte den los navegadores a los Service Workers y a IndexedDB. Una evaluación nueva necesita conexión, porque la inferencia corre en el servidor.

Y el modelo solo puede ser tan preciso como los datos que ingrese el usuario, ya que el sistema no tiene forma de verificarlos clínicamente.

IV-F. *Operación sin conexión y ubicación de la inferencia*

La estimación del riesgo y el cálculo de su explicación se ejecutan en el servidor y no en el navegador. La decisión responde a tres razones: garantiza que cada evaluación registre la versión exacta del modelo que la produjo, mantiene una sola copia del modelo sin distribuir lógica en el cliente y permite reentrenar o sustituir el modelo sin modificar la aplicación instalada. En consecuencia, la aplicación no calcula evaluaciones nuevas sin conexión; lo que sí garantiza sin red es el acceso a la última evaluación con su explicación y a las recomendaciones ya generadas, como se detalla en la tabla siguiente.

La explicación no requiere ejecutar el modelo en el dispositivo porque se calcula junto con la predicción y se almacena con ella. Como el modelo seleccionado es lineal en la escala logit, el valor SHAP de cada variable se obtiene en forma cerrada, sin el muestreo que exigen los métodos genéricos de explicación [14]. Esto resuelve la aparente contradicción entre operación sin conexión y explicabilidad: la explicación de un resultado existe desde el momento en que el resultado existe. Dado que el modelo consta de siete coeficientes y un intercepto, su ejecución en el navegador es técnicamente factible y queda planteada como mejora posterior para permitir evaluaciones completamente sin conexión.

V. OBJETIVOS

V-A. *Objetivo general*

Desarrollar Pulso, una Aplicación Web Progresiva basada en inteligencia artificial para la predicción del riesgo cardiovascular, la generación de recomendaciones alimenticias con ingredientes específicos, planes de vida saludable, rutinas de ejercicio personalizadas y seguimiento continuo, dirigida a personas adultas entre 40 y 69 años residentes en Colombia sin diagnóstico previo de enfermedad cardiovascular.

V-B. *Objetivos específicos*

Para alcanzar el objetivo general se formulan los siguientes objetivos específicos, derivados de las causas raíz priorizadas en el planteamiento del problema:

1) Diseñar la arquitectura de Pulso como Aplicación Web Progresiva y seleccionar el modelo de estimación del riesgo cardiovascular entre regresión logística, gradient boosting y k vecinos más cercanos, entrenados sobre la encuesta NHANES 2021-2023, justificando la elección por su discriminación, su calibración y su interpretabilidad, y definiendo qué funciones operan sin conexión mediante Service Workers e IndexedDB y dónde se ejecuta la inferencia.

2) Desarrollar los módulos funcionales de Pulso, a saber, estimación del riesgo con el modelo seleccionado y explicación de cada predicción mediante valores SHAP calculados de forma exacta, recomendaciones alimenticias con ingredientes específicos y alternativas según la región del país, planes de

TABLA I
COMPORTAMIENTO DE LAS FUNCIONES DE PULSO SEGÚN LA CONECTIVIDAD

Función	Con conexión	Sin conexión
Consultar la última evaluación y la contribución de cada variable	Disponible	Disponible, desde la copia local en IndexedDB
Registrar datos clínicos y de estilo de vida	Se envían y se evalúan de inmediato	Se guardan en la cola local y se evalúan al reconectar
Calcular una evaluación nueva del riesgo	Disponible, en el servidor	No disponible; la aplicación lo indica al usuario
Consultar plan alimentario, lista de mercado, rutinas y hábitos	Disponible	Disponible, desde la caché del Service Worker
Generar un plan alimentario o una rutina nuevos	Disponible	No disponible
Consultar el histórico y exportar el reporte PDF	Disponible	Disponible con los datos sincronizados hasta la última conexión
Recibir notificaciones push	Disponible	Se entregan cuando el dispositivo recupera la conexión

Nota: elaboración propia.

vida saludable, rutinas de ejercicio con progresividad automática y sistema de seguimiento con tablero de evolución y reportes exportables en PDF.

3) Validar el prototipo mediante métricas de desempeño del modelo (área bajo la curva ROC, calibración, sensibilidad y especificidad en el umbral operativo), pruebas de usabilidad con la escala SUS con usuarios representativos en distintos dispositivos y condiciones de conectividad, y la revisión de pertinencia clínica por parte de un profesional de salud.

VI. METODOLOGÍA

Este apartado distingue dos cosas que suelen confundirse. La metodología de investigación responde a cómo se estudia y se evalúa el problema; el marco de desarrollo responde a cómo se construye la solución técnica. Ambas conviven en el proyecto y emplean instrumentos distintos. A continuación se presentan las dos, seguidas del tratamiento que recibirán los datos personales, el procedimiento de preparación y limpieza de los conjuntos de datos y el plan de pruebas.

VI-A. Metodología de investigación

El enfoque de investigación adoptado es mixto, en tanto combina la medición cuantitativa del desempeño con la interpretación cualitativa de la pertinencia y la experiencia de uso. El enfoque se deriva de la pregunta de investigación: para saber cómo contribuye la aplicación a predecir y prevenir el riesgo hacen falta tanto mediciones como juicio experto, y ninguna de las dos basta por sí sola.

El componente cuantitativo indica si el sistema funciona: el desempeño del modelo en el conjunto de prueba, los puntajes de usabilidad, la finalización de tareas y el cumplimiento de los criterios técnicos de una PWA son magnitudes que se pueden verificar y comparar. El componente cualitativo permite establecer si el sistema sirve: la pertinencia clínica de una recomendación alimenticia, la seguridad de una rutina de ejercicio para una persona con riesgo alto o la razón por la cual un usuario abandona un formulario no se obtienen de un promedio, sino de la revisión de un profesional de salud y de la observación directa durante las pruebas.

Según la clasificación por tipo de pregunta, la investigación es de carácter evaluativo o aplicado, dado que no busca caracterizar un fenómeno ni establecer una correlación, sino determinar en qué medida una solución propuesta produce el efecto esperado sobre un problema previamente delimitado.

Los instrumentos de recolección previstos son los siguientes:

- Benchmarking de las herramientas digitales de tamizaje cardiovascular existentes, contrastadas frente a los criterios de acceso libre, funcionamiento sin conexión, integración de recomendaciones y contextualización regional. Sustenta el vacío identificado en los antecedentes.
- Métricas de desempeño de los modelos candidatos (área bajo la curva ROC, puntaje de Brier, calibración, sensibilidad y especificidad), obtenidas por validación cruzada estratificada, como instrumento cuantitativo principal de evaluación del primer y segundo objetivo específico.
- Cuestionario estandarizado de usabilidad, la escala SUS [15], aplicado a usuarios representativos del rango de 40 a 69 años, complementado con el registro de tasa de finalización, tiempo por tarea y errores cometidos.
- Listas de verificación técnica, empleadas para auditar el cumplimiento de los criterios de aplicación web progresiva y de los controles de seguridad definidos.
- Entrevista semiestructurada a un profesional de salud, orientada a valorar la pertinencia y la seguridad de las recomendaciones alimenticias y de las rutinas de ejercicio.
- Observación directa durante las sesiones de usabilidad, con notas de campo sobre las dificultades que el cuestionario no alcanza a registrar.

Para las pruebas de usabilidad se prevén entre diez y quince usuarios, un número que alcanza para encontrar la mayoría de los problemas de usabilidad importantes en una evaluación de este tipo. La muestra no es estadísticamente representativa de la población objetivo ni pretende serlo: lo que se busca es encontrar defectos de interacción, no estimar parámetros de la población.

VI-B. Validación de los instrumentos

Antes de aplicar un instrumento hay que validarlo. Un cuestionario mal formulado produce datos que parecen buenos sin serlo, y el error no se nota durante el análisis. Por eso se prevén tres mecanismos de validación, según el tipo de instrumento.

VI-B1. Juicio de expertos: Antes de aplicarlos, dos o tres personas con experiencia en el área revisan el cuestionario de usabilidad y el guion de la entrevista al profesional de salud. La revisión evalúa tres criterios: pertinencia de cada ítem respecto del objetivo que pretende medir, claridad de la redacción para la población objetivo y suficiencia del conjunto de ítems para cubrir la dimensión evaluada. Las observaciones recibidas y los ajustes aplicados se documentan como evidencia del proceso.

VI-B2. Prueba piloto: Los instrumentos revisados se aplican a una muestra pequeña de entre tres y cinco personas, con el propósito de detectar preguntas ambiguas, problemas de comprensión del vocabulario técnico y fallas operativas en la sesión de prueba, tales como tareas mal enunciadas o tiempos de sesión mal estimados. Los participantes del piloto no se incluyen en la muestra final.

VI-B3. Confiabilidad: Para el cuestionario de usabilidad, que es un instrumento cuantitativo de escala, se calcula el coeficiente alfa de Cronbach como medida de consistencia interna. Un valor superior a 0,7 se considera aceptable. En caso de obtener un valor inferior, se revisan los ítems con menor correlación con el total antes de reportar cualquier resultado derivado del instrumento.

VI-B4. Validación de los instrumentos técnicos: Los instrumentos técnicos (las auditorías de rendimiento y de criterios PWA, las listas de verificación de seguridad y las mediciones de desempeño del modelo) no se pueden validar con juicio de expertos ni con consistencia interna. En su caso, validar significa comprobar que son repetibles: cada medición se corre varias veces en condiciones controladas y equivalentes, y se verifica que los resultados coincidan. En el caso del modelo predictivo, la validación cruzada cumple esa función, dado que evita que el desempeño reportado dependa de una partición particular de los datos.

VI-C. Marco de desarrollo de la solución

La construcción del sistema se realiza combinando Kanban y Programación Extrema (XP). De Kanban se adopta la gestión visual del flujo de trabajo, la limitación del trabajo en curso y las métricas de tiempo de ciclo, que permiten mantener un ritmo sostenido en un equipo reducido y evidenciar los cuellos de botella sin imponer la estructura de sprints. De XP se toman las prácticas que cuidan la calidad del código: iteraciones cortas que terminan en entregas funcionales, desarrollo guiado por pruebas, revisión del código entre los integrantes, integración continua y refactorización constante.

Este marco usa instrumentos propios, distintos de los de la investigación: un backlog de producto construido a partir de los módulos del alcance, historias de usuario con criterios de aceptación verificables, un tablero Kanban con límites de

trabajo en curso y una definición de terminado, wireframes y mockups de la interfaz, diagramas UML de clases y de casos de uso, el modelo entidad-relación de la base de datos y un flujo de integración continua.

El criterio rector es la trazabilidad. Cada incremento debe poder rastrearse hasta un requisito, ese requisito hasta una de las causas priorizadas en el planteamiento del problema y esa causa hasta uno de los objetivos específicos, de modo que ninguna funcionalidad se incorpore sin justificación en el análisis del problema.

VI-D. Tratamiento de datos personales

El proyecto adopta el principio de privacidad desde el diseño. La decisión de mantener los datos en el dispositivo del usuario mediante IndexedDB no obedece únicamente al funcionamiento sin conexión: constituye también la principal medida de protección de la privacidad, puesto que reduce el volumen de datos sensibles que salen del control directo del titular.

El tratamiento de los datos se rige por la Ley 1581 de 2012 y sus decretos reglamentarios, y la Superintendencia de Industria y Comercio vigila que se cumpla. Los datos clínicos y de estilo de vida son datos sensibles: para tratarlos se necesita la autorización explícita del titular y no se puede recolectar ninguno por defecto.

A partir de ahí se fijan estas reglas:

- Minimización: solo se piden los datos necesarios para estimar el riesgo y generar las recomendaciones.
- Consentimiento: la autorización para tratar datos sensibles se pide aparte del registro y el usuario puede retirarla cuando quiera.
- Transparencia: la política de tratamiento de datos se puede leer dentro de la aplicación y está escrita para que la entienda alguien sin formación jurídica.
- Portabilidad y supresión: el usuario puede descargar todos sus datos en un formato legible por máquina, y al eliminar su cuenta, después de confirmarlo, se borran sus datos del dispositivo y del servidor.
- No cesión: el sistema no comparte datos identificables con terceros ni incorpora servicios de analítica que transmitan información de salud.
- Reentrenamiento: cualquier uso de datos para reentrenar el modelo se realiza sobre información anonimizada y previa autorización específica del titular.
- Conservación: se define y se comunica un periodo máximo de conservación de los datos de cuentas inactivas.

VI-E. Preparación y limpieza de los datos

El modelo predictivo se entrena sobre la Encuesta Nacional de Examen de Salud y Nutrición de los Estados Unidos (NHANES), ciclo agosto de 2021 a agosto de 2023 [10]. Se escogió por cuatro motivos: es reciente; es de dominio público y se descarga sin pasar por un comité de ética; el pulso, el peso y el índice de masa corporal se miden en un centro de examen, y es la única fuente verificada que reúne las variables que registra la aplicación junto con un

desenlace cardiovascular. El UCI Heart Disease [11], [16] se usa solo para verificar la implementación de los algoritmos, porque sus variables de laboratorio no coinciden con las que registra Pulso, y el WHO Global Health Observatory sirve como referencia epidemiológica, porque publica indicadores agregados por país y no datos de personas.

El procedimiento tiene cinco etapas. En la primera, la unificación, se cruzan por el identificador del participante los siete archivos del ciclo que tienen las variables de interés (demografía, presión y pulso, medidas corporales, sueño, PHQ-9, tabaquismo y antecedentes médicos), y cada variable se convierte a las unidades y escalas de la aplicación, como se muestra en la tabla siguiente.

La segunda etapa es el análisis exploratorio: se describe la distribución de cada variable, cuántos valores faltan y cómo se correlacionan los predictores, y se compara la muestra según tenga o no antecedente cardiovascular.

La tercera etapa es la limpieza. Entran los adultos de 18 años o más que tienen completos el pulso, el peso, el índice de masa corporal, las horas de sueño y los nueve ítems del PHQ-9, y cuyo desenlace se conoce. Las variables predictoras centrales no se imputan: si un registro está incompleto se excluye, y cada exclusión queda anotada en el flujo de construcción de la muestra. Al final quedan 5.043 adultos, de los cuales 597 tienen antecedente cardiovascular (11,8 %).

La cuarta etapa, la transformación, estandariza las variables continuas con la media y el desvío de cada partición de entrenamiento, nunca con los de prueba, para no filtrar información de la evaluación, y lleva el PHQ-9 a la escala de estrés de 1 a 10 de la aplicación.

La quinta etapa es la partición. La prevalencia del desenlace es de 11,8 %; no se aplica sobremuestreo ni submuestreo, porque ambas técnicas distorsionan la probabilidad que el modelo entrega y la aplicación muestra esa probabilidad al usuario [17]. Para manejar el desbalance se usan métricas que no dependen de la proporción de clases y se elige con cuidado el umbral operativo. La evaluación se hace con validación cruzada estratificada de cinco particiones, repetida diez veces.

Todo el procedimiento está programado en scripts del repositorio del proyecto, de modo que cualquier resultado reportado se puede regenerar a partir de los datos originales.

VI-F. Modelos de aprendizaje automático evaluados

El modelo de estimación del riesgo se escoge de forma empírica entre tres algoritmos entrenados, que se comparan con dos referentes. Todos se implementan en el proyecto siguiendo la formulación de Hastie, Tibshirani y Friedman [18] y se evalúan sobre las mismas particiones.

Random Forest [22] y XGBoost [23] no se evalúan por separado porque pertenecen a la misma familia de conjuntos de árboles que gradient boosting: si este no supera a la regresión logística, no existe estructura no lineal que justifique otros miembros de la familia. Las redes neuronales, que muestran buen desempeño sobre grandes volúmenes de datos clínicos [4], [5], se descartan porque con siete variables tabulares y cerca de cinco mil observaciones no se espera ganancia

de discriminación y se pierde la explicación exacta de cada predicción.

Para elegir se aplica un criterio de parsimonia: gana el modelo más simple cuya área bajo la curva no sea superada de forma estadísticamente significativa por la de otro, siempre que cumpla los criterios de calibración del apartado VII. En el modelo lineal, el valor SHAP de cada variable tiene forma cerrada, $\phi_i = \beta_i(x_i - \bar{x}_i)$ en la escala logit [14], así que la explicación sale al mismo tiempo que la predicción, sin muestreo ni bibliotecas adicionales.

VI-G. Plan de pruebas

La validación del prototipo se organiza en cinco frentes.

VI-G1. Desempeño del modelo predictivo: Cada modelo candidato se evalúa sobre las mismas 50 particiones de prueba de la validación cruzada con el área bajo la curva ROC [24] y el puntaje de Brier, y el modelo seleccionado, además, con la pendiente y el intercepto de calibración, el diagrama de calibración por deciles [17] y, en el umbral de Youden [25], la sensibilidad, la especificidad, los valores predictivos y la matriz de confusión. Las diferencias de área bajo la curva entre modelos se estiman con bootstrap pareado de 2.000 remuestreos [26]. La sensibilidad se prioriza sobre la exactitud global, dado que en un contexto de tamizaje un falso negativo, es decir una persona en riesgo clasificada como segura, tiene un costo considerablemente mayor que un falso positivo. Los valores SHAP se emplean además como verificación cualitativa: si las variables que el modelo pondera como determinantes no coinciden con los factores de riesgo reconocidos clínicamente, existe un problema en los datos o en el entrenamiento aunque las métricas resulten aceptables.

VI-G2. Pruebas de software: Hay pruebas unitarias para la lógica del cálculo del riesgo y para las reglas que generan las recomendaciones, pruebas de integración entre los módulos de predicción, alimentación, ejercicio y seguimiento, y pruebas de extremo a extremo que recorren el flujo completo, desde que el usuario ingresa sus datos hasta que se genera el reporte.

VI-G3. Pruebas de arquitectura PWA y conectividad: Se comprueba que la aplicación se pueda instalar en teléfonos, tabletas y computadores de escritorio; se audita con Lighthouse en rendimiento, accesibilidad y criterios PWA, y se prueba en modo avión que el usuario pueda consultar su última evaluación con la explicación y las recomendaciones ya cargadas, que los registros queden guardados en IndexedDB y que la evaluación pendiente se calcule cuando vuelva la red.

VI-G4. Pruebas de seguridad: Se revisa que la aplicación cumpla los controles definidos a partir del OWASP Top 10 Web y del estándar OWASP Mobile, con especial cuidado en cómo se guardan los datos sensibles en el dispositivo, cómo se manejan las sesiones y qué expone la interfaz de programación de la aplicación.

VI-G5. Pruebas de usabilidad y revisión clínica: Usuarios representativos de 40 a 69 años realizan un conjunto de tareas definidas mientras se mide la tasa de finalización, el tiempo por tarea y los errores; al terminar responden un instrumento estandarizado de satisfacción. De forma paralela,

TABLA II
CORRESPONDENCIA ENTRE LAS VARIABLES DE LA APLICACIÓN Y LAS DE NHANES 2021-2023

Variable en Pulso	Código en NHANES	Observación
Frecuencia cardíaca en reposo	BPXOPLS1	Pulso de la primera lectura oscilométrica, tras cinco minutos sentado
Peso e índice de masa corporal	BMXWT, BMXBMI	Medidos en el centro de examen, no autorreportados
Horas de sueño	SLD012	Horas de sueño en días laborables
Estrés (1 a 10)	DPQ010 a DPQ090	Puntaje total del PHQ-9 [13], llevado a la escala de la aplicación; es una aproximación
Tabaquismo	SMQ020, SMQ040	Fumador actual: al menos 100 cigarrillos en la vida y fuma todos o algunos días
Edad y sexo	RIDAGEYR, RIAGENDR	La encuesta agrupa en 80 las edades de 80 años o más
Antecedente cardiovascular (desenlace)	MCQ160B a MCQ160F	Falla cardíaca, enfermedad coronaria, angina, infarto o accidente cerebrovascular, autorreportados

Nota: elaboración propia a partir de la documentación de NHANES 2021-2023.

TABLA III
CONSTRUCCIÓN DE LA MUESTRA ANALÍTICA DE NHANES 2021-2023

Criterio	Participantes
Participantes del ciclo (archivo demográfico)	11.933
Adultos de 18 años o más	8.153
Con pulso en reposo medido	6.123
Con peso e índice de masa corporal medidos	6.061
Con horas de sueño reportadas	6.003
Con los nueve ítems del PHQ-9 respondidos	5.282
Con desenlace cardiovascular conocido (muestra analítica)	5.043

Nota: elaboración propia.

un profesional de salud revisa la pertinencia y la seguridad de las recomendaciones alimenticias y de las rutinas de ejercicio antes de cualquier prueba con usuarios finales.

VI-H. Matriz de trazabilidad metodológica

La cadena metodológica del proyecto va del tema a la respuesta pasando por la pregunta, el enfoque, el instrumento, los datos y el análisis, y cada eslabón depende del anterior. La siguiente matriz hace explícita esa cadena para cada objetivo específico, de modo que ningún resultado quede sin instrumento que lo produzca ni ningún instrumento sin objetivo que lo justifique.

El componente cuantitativo y el cualitativo se integran en el tercer objetivo mediante una secuencia explicativa: primero se aplica el cuestionario y se registran las métricas de tarea, y a continuación se profundiza cualitativamente sobre los casos que presentaron los puntajes más bajos o las dificultades más frecuentes, con el fin de establecer las razones que las métricas por sí solas no explican.

VII. RESULTADOS ESPERADOS Y PLAN DE ANÁLISIS

Este apartado define qué se va a reportar como resultado, con qué instrumento se obtiene y en qué formato se presenta. La distinción operativa es que los resultados corresponden a lo encontrado de forma objetiva y verificable, es decir datos, métricas y hallazgos, mientras que su interpretación, la

comparación con la teoría y las implicaciones corresponden a la discusión y no se anticipan aquí.

La presentación de resultados se rige por cuatro principios. Primero, la organización por objetivo: cada objetivo específico tiene su propia sección de resultados y no se presentan en un bloque continuo. Segundo, mostrar antes de explicar: la tabla, la figura o la evidencia se presentan primero y el texto descriptivo va después. Tercero, la afirmación verificable: cada resultado se enuncia con cifras concretas y el tamaño de la muestra correspondiente, evitando adjetivos valorativos como excelente, notable o muy bueno. Cuarto, la trazabilidad: cada resultado indica el instrumento que lo generó, según la matriz del apartado VI-H.

El proyecto combina dos dominios y por tanto debe reportar resultados de ambos: los propios del desarrollo de software, como historias completadas frente a planeadas, resultados de pruebas y evidencia de funcionamiento, y los propios de la ciencia de datos, como métricas del modelo, comparación entre algoritmos y descripción del conjunto de datos empleado.

VII-A. Resultados del primer objetivo específico

Se reportan la arquitectura definida, la selección tecnológica y la selección del modelo. Como evidencia se presentan el diagrama de arquitectura, el diagrama de clases, el modelo entidad-relación, una matriz de decisión tecnológica que compara cada componente elegido con al menos dos alternativas según criterios explícitos, y la comparación entre regresión logística, gradient boosting y k vecinos más cercanos que justifica el modelo elegido y que se presenta en el apartado siguiente. También se incluye una tabla de cobertura que relaciona cada requisito funcional y no funcional con el componente de la arquitectura que lo cumple.

VII-B. Resultados del segundo objetivo específico

Del lado del modelo predictivo se reportan la descripción de la muestra analítica, con el flujo de exclusiones presentado en el apartado VI-E; la comparación de los cinco modelos del apartado VI-F con su área bajo la curva ROC y su puntaje de Brier sobre las 50 particiones de prueba; la calibración,

TABLA IV
ALGORITMOS CANDIDATOS Y REFERENTES

Algoritmo	Familia	Razón para evaluarlo	Configuración
Regresión logística	Lineal generalizado	Interpretable, produce probabilidades y admite explicación exacta por variable	Mínimos cuadrados reponderados iterativamente con penalización ridge $\lambda = 0,01$ [19]; variables estandarizadas por partición
Gradient boosting	Conjunto de árboles	Detecta no linealidades e interacciones; representa a la familia de Random Forest y XGBoost	100 rondas, árboles de profundidad 3, tasa de aprendizaje 0,1 [20]
k vecinos más cercanos	No paramétrico	Comparador sin supuestos de forma funcional	Distancia euclídea sobre variables estandarizadas, k = 65 [21]
Prevalencia	Referente	Línea base sin discriminación	Asigna a todos la prevalencia observada
Regresión logística con edad y sexo	Referente	Mide cuánto aportan las variables de estilo de vida	Igual a la regresión logística, con dos variables

Nota: elaboración propia.

TABLA V
TRAZABILIDAD ENTRE OBJETIVOS ESPECÍFICOS, INSTRUMENTOS, DATOS Y TÉCNICAS DE ANÁLISIS

Objetivo específico	Instrumento	Dato que produce	Técnica de análisis
OE1. Diseñar la arquitectura de la PWA y seleccionar los modelos	Benchmarking de herramientas existentes, matriz de decisión tecnológica con criterios ponderados y comparación de modelos por validación cruzada	Comparación de alternativas por criterio; componentes seleccionados con su justificación; AUC y Brier de cada modelo candidato	Análisis comparativo por criterios; verificación de cobertura de los requisitos; bootstrap pareado de diferencias de AUC
OE2. Desarrollar los módulos funcionales	Métricas de desempeño del modelo sobre el conjunto de prueba; registro de historias completadas; pruebas automatizadas	AUC-ROC, Brier, calibración, sensibilidad, especificidad y matriz de confusión del modelo seleccionado; valores SHAP exactos; historias completadas frente a planeadas; cobertura de pruebas	Estadística descriptiva; validación cruzada estratificada 5×10 ; odds ratio con intervalos de confianza; verificación de las contribuciones por variable
OE3. Validar el prototipo	Cuestionario estandarizado de usabilidad; registro de tareas; listas de verificación técnica; entrevista semiestructurada al profesional de salud; observación con notas de campo	Puntaje de usabilidad por participante; tasa de finalización, tiempo y errores por tarea; puntajes de auditoría técnica; hallazgos clínicos; incidentes observados	Estadística descriptiva con media y desviación; alfa de Cronbach; análisis temático de las respuestas abiertas y de las notas de observación

Nota: elaboración propia.

la matriz de confusión, la sensibilidad y la especificidad del modelo seleccionado en el umbral operativo; y, en lugar de una figura genérica de importancia de variables, la tabla de odds ratio del modelo con sus intervalos de confianza, que es la base de los valores SHAP que ve cada usuario. Para que estos resultados esperados no queden en abstracto, se presentan a continuación los criterios de aceptación de cada métrica junto con el resultado preliminar obtenido al ejecutar la preparación de datos y el protocolo de evaluación sobre NHANES 2021-2023.

La regresión logística con las siete variables alcanza el mayor AUC, 0,805. Frente al modelo con solo edad y sexo, la diferencia es de +0,037, con intervalo de confianza del 95 % de [0,025; 0,049], de modo que las variables que captura la aplicación sí aportan por encima de la demografía. Gradient boosting queda 0,010 por debajo, con intervalo de $[-0,018; -0,001]$, sin evidencia de relaciones no lineales que justifiquen un modelo más flexible. Por el criterio de parsimonia se selecciona la regresión logística. Las variables de estilo de vida por sí solas discriminan poco (0,608), hallazgo que motivó incorporar la edad y el sexo al perfil de la aplicación.

En el umbral operativo, el valor predictivo positivo es de 0,243. Es decir, la herramienta es mejor para descartar

riesgo que para confirmarlo, lo que concuerda con su papel de tamizaje y con la advertencia de que el resultado no es un diagnóstico. La calibración del modelo seleccionado se muestra en la figura siguiente.

Esta tabla ocupa el lugar de la figura de importancia de variables, con la ventaja de que, además del orden, muestra el tamaño de cada asociación y su incertidumbre. Para un usuario concreto, la aplicación ordena sus variables según el valor SHAP exacto; por ejemplo, para una persona con índice de masa corporal alto y sin tabaquismo, indica que el índice de masa corporal es la variable modificable que más aumenta su riesgo frente al promedio y que no fumar lo reduce, lo que orienta directamente las recomendaciones de alimentación y ejercicio.

Del lado del desarrollo: el número de historias de usuario completadas frente a las planeadas, el resultado de las pruebas unitarias y de integración con su cobertura, y la evidencia de funcionamiento de cada módulo mediante capturas de pantalla del prototipo.

Toda métrica se reporta acompañada del tamaño del conjunto sobre el que se calculó. Un valor de exactitud sin el número de casos de prueba no constituye un resultado verificable.

TABLA VI
DISCRIMINACIÓN DEL ANTECEDENTE CARDIOVASCULAR EN NHANES 2021-2023 (RESULTADO PRELIMINAR)

Algoritmo	Variables	AUC (media $\pm$ desvío)	Brier
Prevalencia	Ninguna	0,500 $\pm$ 0,000	0,104
Regresión logística	Edad y sexo	0,769 $\pm$ 0,013	0,094
Regresión logística	Estilo de vida (5)	0,608 $\pm$ 0,025	0,103
Gradient boosting	Estilo de vida (5)	0,605 $\pm$ 0,025	0,105
Regresión logística	Estilo de vida, edad y sexo (7)	0,805 $\pm$ 0,014	0,091
Gradient boosting	Estilo de vida, edad y sexo (7)	0,794 $\pm$ 0,016	0,093
k vecinos más cercanos (k = 65)	Estilo de vida, edad y sexo (7)	0,775 $\pm$ 0,017	0,094

Nota: validación cruzada estratificada 5×10 , $n = 5.043$. El estilo de vida comprende frecuencia cardíaca, índice de masa corporal, horas de sueño, PHQ-9 y tabaquismo. Elaboración propia.

TABLA VII
CRITERIOS DE ACEPTACIÓN DEL MODELO Y RESULTADO PRELIMINAR

Métrica	Criterio de aceptación	Justificación	Resultado preliminar
AUC con siete variables	$\geq 0,75$	Discriminación útil para tamizaje poblacional	0,805 $\pm$ 0,014
Aporte del estilo de vida	Intervalo del Δ AUC frente a edad y sexo sin el cero	Las variables que captura la aplicación deben aportar	+0,037 [0,025; 0,049]
Pendiente de calibración	Entre 0,8 y 1,2	La probabilidad mostrada al usuario debe ser creíble	0,99
Intercepto de calibración	Entre -0,1 y 0,1	Sin sobrestimación ni subestimación global	-0,02
Puntaje de Brier	Menor que el de la prevalencia (0,104)	Mejora sobre no usar modelo	0,091
Sensibilidad en el umbral operativo	$\geq 0,80$	En tamizaje, no detectar cuesta más que una falsa alarma	0,822 (umbral 0,11)
Especificidad en el umbral operativo	$\geq 0,60$	Limita las derivaciones innecesarias	0,656
Valor predictivo negativo	$\geq 0,95$	Un resultado de riesgo bajo debe ser confiable	0,965

Nota: el umbral de Youden se eligió sobre las mismas predicciones que se evalúan, por lo que la sensibilidad y la especificidad son levemente optimistas. Elaboración propia.

TABLA VIII
ODDS RATIO DE LA REGRESIÓN LOGÍSTICA SELECCIONADA (RESULTADO PRELIMINAR)

Variable	OR por 1 DE (IC 95 %)	OR por unidad (IC 95 %)	Unidad
Edad	4,06 (3,51–4,69)	2,27 (2,09–2,47)	+10 años
Índice de masa corporal	1,46 (1,33–1,60)	1,30 (1,22–1,39)	+5 kg/m ²
Sexo masculino	1,41 (1,28–1,55)	2,00 (1,65–2,41)	Hombre frente a mujer
PHQ-9	1,39 (1,27–1,52)	1,43 (1,30–1,57)	+5 puntos
Fumador actual	1,24 (1,14–1,35)	1,85 (1,44–2,37)	Sí frente a no
Horas de sueño	1,14 (1,04–1,24)	1,09 (1,03–1,15)	+1 hora
Frecuencia cardíaca en reposo	1,11 (1,01–1,21)	1,08 (1,01–1,17)	+10 lpm

Nota: DE: desvío estándar. Todos los coeficientes tienen $p < 0,05$. El odds ratio del sueño es positivo porque el sueño largo también se asocia con mayor riesgo y, en un diseño transversal, está confundido por la edad y la morbilidad previa. Elaboración propia.

VII-C. Resultados del tercer objetivo específico

Los resultados de la validación se reportan en cuatro bloques. El primero, de usabilidad, incluye el puntaje promedio del cuestionario con su desviación estándar y el número de participantes, la distribución de los puntajes individuales y el alfa de Cronbach obtenido. El segundo, de desempeño en tarea, presenta en una tabla la tasa de finalización, el tiempo promedio y los errores de cada tarea evaluada. El tercero, de auditoría técnica, recoge los puntajes de rendimiento, accesibilidad y criterios PWA, y el nivel de cumplimiento de los controles de seguridad por categoría. El cuarto, de revisión clínica, lista los hallazgos del profesional de salud por severidad, junto con el ajuste hecho en respuesta a cada

uno.

También se informa cómo se comportó el sistema sin conexión: qué funciones siguieron disponibles, si los datos se guardaron bien en el dispositivo y si la sincronización terminó al volver la red.

VII-D. Formato de presentación

Las tablas y figuras se numeran en orden, llevan un rótulo que describe su contenido y se mencionan en el texto antes de aparecer. Los resultados negativos o por debajo de lo esperado se reportan con el mismo detalle que los favorables: un instrumento con baja confiabilidad o un modelo que no llega a la sensibilidad exigida también son hallazgos, y omitirlos afectaría la integridad del trabajo.

TABLA IX
CRITERIOS DE ACEPTACIÓN DE LA APLICACIÓN

Aspecto	Criterio de aceptación	Instrumento
Usabilidad percibida	Puntaje SUS medio ≥ 70 , cercano a la media reportada en la literatura [27]	Escala SUS
Autonomía	Al menos el 80 % de los participantes completa la primera evaluación sin asistencia	Registro de tareas
Operación sin conexión	La última evaluación con su explicación, el plan, las rutinas y el histórico se consultan en modo avión en todos los dispositivos de prueba	Lista de verificación técnica
Rendimiento	Primera carga útil en menos de 3 s con 3G simulada y resultado del riesgo en menos de 2 s con conexión	Lighthouse y registro del servidor
Pertinencia clínica	Sin observaciones críticas del profesional sobre categorías de riesgo y mensajes de derivación	Entrevista semiestructurada

Nota: elaboración propia.

Calibración por deciles (fuera de muestra, $n \approx 504$ por decil)




Figura 1. Calibración por deciles de riesgo predicho de la regresión logística con estilo de vida, edad y sexo, resultado preliminar. Elaboración propia.

VIII. CONCLUSIONES

El problema de las enfermedades cardiovasculares en Colombia no se debe a que falte conocimiento clínico, sino a que el riesgo se detecta tarde. Como el tamizaje depende de que la persona vaya a consulta, quien no consulta sigue sin evaluar hasta que tiene un evento agudo. Si a eso se suma la desigualdad territorial en servicios preventivos y en conectividad, queda una brecha en la que la ingeniería de sistemas puede intervenir.

La revisión de antecedentes muestra que las piezas técnicas ya existen y están validadas, aunque por separado: modelos de aprendizaje automático que igualan o superan a las escalas de riesgo tradicionales, nutrición personalizada con evidencia clínica medible, sistemas que recomiendan actividad física con mejor adherencia que las indicaciones genéricas y PWA probadas en salud pública. Lo que falta es unirlos, y eso es lo que propone Pulso.

La elección de una arquitectura de Aplicación Web Progresiva responde de manera directa a las restricciones del contexto colombiano. La consulta sin conexión mediante Ser-

vice Workers, el almacenamiento local con IndexedDB y la instalación sin dependencia de tiendas de aplicaciones no son decisiones estéticas, sino la respuesta técnica a la conectividad intermitente y a los dispositivos de gama baja que predominan en la población con mayor barrera de acceso.

La elección del modelo pesa lo mismo. En NHANES 2021-2023, una regresión logística con las variables de estilo de vida, la edad y el sexo alcanza un área bajo la curva ROC de 0,805 con buena calibración, y ni gradient boosting ni k vecinos más cercanos la superan. Como el modelo es lineal, el valor SHAP exacto de cada variable se obtiene en el mismo momento de la predicción; la explicación se guarda junto con la evaluación y se puede consultar sin conexión, de modo que explicar el resultado y funcionar sin red dejan de estar en conflicto. Dado que la literatura señala la escasa validación externa y el carácter de caja negra de los modelos como obstáculos principales para su adopción [4], un resultado auditable por el usuario y por el profesional de salud constituye una condición de confianza y no un añadido opcional.

Finalmente, el proyecto reconoce de forma explícita los límites de su alcance. El conjunto de entrenamiento proviene de población estadounidense y no colombiana, su diseño transversal no permite estimar incidencia futura, las recomendaciones tienen carácter orientativo y no sustituyen el criterio médico profesional, una evaluación nueva requiere conexión y el sistema opera por evaluación periódica y no por monitoreo continuo. La validación con datos poblacionales colombianos y la revisión clínica del prototipo quedan planteadas como condición para cualquier uso más allá del ámbito académico, y como línea natural de trabajo posterior.

REFERENCIAS

- [1] Ministerio de Salud y Protección Social de Colombia, "Análisis de Situación de Salud (ASIS) Colombia," Bogotá, Colombia, 2022. [En línea]. Disponible en: <https://www.minsalud.gov.co>
- [2] Organización Mundial de la Salud, "Enfermedades cardiovasculares," Nota descriptiva, 2025. [En línea]. Disponible en: [https://www.who.int/es/news-room/fact-sheets/detail/cardiovascular-diseases-\(cvds\)](https://www.who.int/es/news-room/fact-sheets/detail/cardiovascular-diseases-(cvds))
- [3] World Heart Federation, "World Heart Report 2023: Confronting the world's number one killer," Ginebra, Suiza, 2023. [En línea]. Disponible en: <https://world-heart-federation.org/wp-content/uploads/World-Heart-Report-2023.pdf>
- [4] C. Krittanawong et al., "Machine learning prediction in cardiovascular diseases: A meta-analysis," Sci. Rep., vol. 10, no. 1, Art. no. 16057, 2020, doi: 10.1038/s41598-020-72685-1.

- [5] S. F. Weng, J. Reps, J. Kai, J. M. Garibaldi y N. Qureshi, "Can machine-learning improve cardiovascular risk prediction using routine clinical data?," *PLoS ONE*, vol. 12, no. 4, Art. no. e0174944, 2017, doi: 10.1371/journal.pone.0174944.
- [6] SCORE2 working group and ESC Cardiovascular risk collaboration, "SCORE2 risk prediction algorithms: New models to estimate 10-year risk of cardiovascular disease in Europe," *Eur. Heart J.*, vol. 42, no. 25, pp. 2439–2454, 2021, doi: 10.1093/eurheartj/ehab309.
- [7] D. Zeevi et al., "Personalized nutrition by prediction of glyce-mic responses," *Cell*, vol. 163, no. 5, pp. 1079–1094, 2015, doi: 10.1016/j.cell.2015.11.001.
- [8] P. Liao, K. Greenewald, P. Klasnja y S. Murphy, "Personalized Hear-tSteps: A reinforcement learning algorithm for optimizing physical activity," *Proc. ACM Interact. Mob. Wearable Ubiquitous Technol.*, vol. 4, no. 1, 2020, doi: 10.1145/3381007.
- [9] D. Biduski, E. A. Bellei, J. P. M. Rodriguez, L. A. M. Zaina y A. C. B. De Marchi, "Assessing long-term user experience on a mobile health application through an in-app embedded conversation-based question-naire," *Comput. Hum. Behav.*, vol. 104, Art. no. 106169, 2020, doi: 10.1016/j.chb.2019.106169.
- [10] Centers for Disease Control and Prevention, National Center for Health Statistics, "National Health and Nutrition Examination Survey: August 2021 – August 2023 data files," U.S. Department of Health and Human Services, Hyattsville, MD, EE. UU., 2024. [En línea]. Disponible en: <https://wwwn.cdc.gov/nchs/nhanes/continuousnhanes/default.aspx?Cycle=2021-2023>
- [11] A. Janosi, W. Steinbrunn, M. Pfisterer y R. Detrano, "Heart Disease," *UCI Machine Learning Repository*, 1988, doi: 10.24432/C52P4X.
- [12] R. B. D'Agostino et al., "General cardiovascular risk profile for use in primary care: The Framingham Heart Study," *Circulation*, vol. 117, no. 6, pp. 743–753, 2008, doi: 10.1161/CIRCULATIONAHA.107.699579.
- [13] K. Kroenke, R. L. Spitzer y J. B. W. Williams, "The PHQ-9: Validity of a brief depression severity measure," *J. Gen. Intern. Med.*, vol. 16, no. 9, pp. 606–613, 2001, doi: 10.1046/j.1525-1497.2001.016009606.x.
- [14] S. M. Lundberg y S.-I. Lee, "A unified approach to interpreting model predictions," en *Advances in Neural Information Processing Systems* 30, 2017, pp. 4765–4774.
- [15] J. Brooke, "SUS: A 'quick and dirty' usability scale," en *Usability Evaluation in Industry*, P. W. Jordan, B. Thomas, B. A. Weerdmeester e I. L. McClelland, Eds. Londres, Reino Unido: Taylor & Francis, 1996, pp. 189–194.
- [16] R. Detrano et al., "International application of a new probability algo-rithm for the diagnosis of coronary artery disease," *Amer. J. Cardiol.*, vol. 64, no. 5, pp. 304–310, 1989, doi: 10.1016/0002-9149(89)90524-9.
- [17] B. Van Calster, D. J. McLernon, M. van Smeden, L. Wynants y E. W. Steyerberg, "Calibration: The Achilles heel of predictive analytics," *BMC Med.*, vol. 17, Art. no. 230, 2019, doi: 10.1186/s12916-019-1466-7.
- [18] T. Hastie, R. Tibshirani y J. Friedman, *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*, 2.ª ed. Nueva York, NY, EE. UU.: Springer, 2009, doi: 10.1007/978-0-387-84858-7.
- [19] S. le Cessie y J. C. van Houwelingen, "Ridge estimators in logistic regression," *J. Roy. Statist. Soc. Ser. C (Appl. Statist.)*, vol. 41, no. 1, pp. 191–201, 1992, doi: 10.2307/2347628.
- [20] J. H. Friedman, "Greedy function approximation: A gradient boosting machine," *Ann. Statist.*, vol. 29, no. 5, pp. 1189–1232, 2001, doi: 10.1214/aos/1013203451.
- [21] T. Cover y P. Hart, "Nearest neighbor pattern classification," *IEEE Trans. Inf. Theory*, vol. 13, no. 1, pp. 21–27, 1967, doi: 10.1109/TIT.1967.1053964.
- [22] L. Breiman, "Random forests," *Mach. Learn.*, vol. 45, no. 1, pp. 5–32, 2001, doi: 10.1023/A:1010933404324.
- [23] T. Chen y C. Guestrin, "XGBoost: A scalable tree boosting system," en *Proc. 22nd ACM SIGKDD Int. Conf. Knowledge Discovery and Data Mining*, 2016, pp. 785–794, doi: 10.1145/2939672.2939785.
- [24] J. A. Hanley y B. J. McNeil, "The meaning and use of the area under a receiver operating characteristic (ROC) curve," *Radiology*, vol. 143, no. 1, pp. 29–36, 1982, doi: 10.1148/radiology.143.1.7063747.
- [25] W. J. Youden, "Index for rating diagnostic tests," *Cancer*, vol. 3, no. 1, pp. 32–35, 1950.
- [26] B. Efron y R. J. Tibshirani, *An Introduction to the Bootstrap*. Nueva York, NY, EE. UU.: Chapman & Hall, 1993.
- [27] A. Bangor, P. T. Kortum y J. T. Miller, "An empirical evaluation of the System Usability Scale," *Int. J. Hum.-Comput. Interact.*, vol. 24, no. 6, pp. 574–594, 2008, doi: 10.1080/10447310802205776.